빅데이터분석 팀 프로젝트 주제 계획서

다음 학년도 중도탈락 고위험 학과는 어디인가

학업지속 지원 대상 학과 선정을 위한
대학알리미 학과별 중도탈락 패널(2023~2026) 분석 및 예측

과 목	빅데이터분석
담당교수	박주원
조	14 조
팀 원	정승엽(202103116), 박유진(202004229), 신효주(202404341)
분석 자료	교육부 대학알리미 중도탈락 학생 현황(대학, 학과별), 공공데이터포털 15164570

2026. 11. 8.

14 조

다음 학년도 중도탈락 고위험 학과는 어디인가

학업지속 지원 대상 학과 선정을 위한 대학알리미 학과별 중도탈락 패널(2023~2026) 분석 및 예측

14 조 - 정승엽, 박유진, 신효주 | 2026. 11. 8. | 한국외국어대학교 AI 기반 비즈니스 데이터 분석 (박주원)

I. 주제 제안서 (제출 양식)

항목	작성 내용
조 / 팀원	14 조: 정승엽(202103116), 박유진(202004229), 신효주(202404341)
의사결정 질문	**누가** 대학 학사지원 담당자가 (적용 사례: 한국외대 학사종합지원센터&입학처) **무엇을** 다음 학년도에 학업지속 지원(상담, 학습지원, 복학 안내)을 우선 배치할 학과를 정하려 한다. **질문** 직전 공시연도 정보로 다음 공시연도의 중도탈락 고위험(상위 25%) 학과를 맞힐 수 있는가? 맞힌다면 '전년도 고위험 학과를 그대로 지원'하는 기준선보다 얼마나 나은가? (분류)
가설	직전 연도의 중도탈락률이 가장 강한 예측 신호이고, 설립유형, 지역, 계열, 규모를 더해도 '전년도 고위험 지속' 기준선 대비 적중률 개선은 5%p 미만일 것이며, 고위험 비율은 비수도권, 사립, 소규모 학과에서 더 높을 것이다. 한국외대 사례로는, 표준분류 소계열이 '기타유럽어 문학', '기타아시아어 문학'인 소규모 어문학과군이 한국외대 내 다른 학과와 전국 동일 소계열 학과보다 중도탈락률이 높아 학업지속 지원의 우선 대상일 것이다.
반대 결과 처리	개선이 5%p 이상이면 기준선 대신 모델 기반 선별을 권고하고 오즈비로 지원 기준을 제시한다. 비수도권, 사립, 소규모의 오즈비가 1 이하이거나 신뢰구간이 1 을 포함하면 지역 및 설립유형 중심 배분 논리를 기각하고 계열과 규모 중심으로 바꾼다. 한국외대 어문군이 두 비교군 모두보다 높지 않으면 학업지속 지원 근거가 약하다고 결론짓고 문제를 이탈이 아닌 모집(입학처) 쪽으로 다시 정의한다. 어느 쪽이든 결과의 한계를 밝힌다.
데이터	교육부_대학알리미_중도탈락 학생 현황_대학_학과별 (제공기관: 교육부 교육데이터정책과) https://www.data.go.kr/data/15164570/fileData.do 56,340 행 × 32 열 / 공시연도 2023~2026 / 공공누리 제 1 유형(출처 표시) / 포털 등록일(수정일) 2026-09-10 / 다운로드일 2026-11-08
분석 방법	분류(로지스틱 회귀) + 교차 분석(탈락 인원 × 탈락률 산점도). 결정이 '지원 대상 선정(예/아니오)'이고 지원 가능 학과 수에 한도가 있어 분류가 맞고, 오즈비로 지원 기준을 설명할 수 있다. 한국외대 사례(H4)는 군 단위 비교(기술통계+부트스트랩).

항목	작성 내용
예측 대상	고위험=1: 당해 중도탈락학생비율 ≥ 학습 기간 유효 학과의 75 백분위. 기준선 ① 전원 '고위험 아님' ② 전년도 고위험이면 올해도 고위험(지속성).
지난 / 이번 발표자	지난 발표자: 박유진 이번 발표자: 신효주 또는 정승엽
탈락 후보	UCI SECOM(반도체 제조 공정 센서 데이터, 공정 합격/불합격 분류). 도메인 지식이 부족한 비전공자라도 4 차 산업 시대에 AI 를 활용하면 해당 분야의 전문가가 아니어도 높은 수준의 분석 결과를 제시할 수 있고, 이를 발판으로 더 깊이 파고들어 도메인 전문가로 성장할 수 있다는 가능성을 보여 주고 싶었다. 그러나 기업의 반도체 공정 데이터는 기밀이 많아 공개 자료로는 현장의 맥락을 얻기 어렵고, SECOM 역시 각 센서가 무엇을 측정하는지에 대한 정보 없이 익명화된 측정값만 담고 있어 변수 해석과 공정 개선 제안으로 이어 가기 어렵다는 한계가 있어 제외했다.

자료: 공공데이터포털 data.go.kr/data/15164570 (교육부, 공공누리 제 1 유형).

II. 데이터 사전 점검

점검 항목	확인한 값	정제 때 처리 원칙
규모와 구조	56,340 행 × 32 열, 4 개 공시연도(연 약 1.4 만 행), 250 개교, 학과 20,158 개	전년→당해 쌍 29,071 개 구성 가능
중복	완전 중복 0 행, (공시연도, 학교, 학과) 키 중복 0 행	처리 없음, 확인 근거만 로그에 기록
결측	중도탈락학생비율 6,372 행(11.3%). 2023 공시 0.8%, 2024~2026 공시 약 15%	행 삭제 금지. 원인(재적 0 등) 분해 후 처리, 연도 간 차이 해석
재적학생 = 0	2,500 행, 그중 1,497 행은 탈락 인원(계)이 1 명 이상	비율 정의 불가: 표시 후 분석 제외, 건수와 근거 로그
비율 이상값	100% 초과 172 행(87%가 재적 5 명 이하), 공시 비율과 계÷재적 재계산이 어긋난 행 68	삭제 대신 표시. 최소 재적 30 명으로 통제, 10 명, 50 명으로 민감도
정합성	사유별 인원의 합 = 계 (불일치 0 행)	사유 구성비를 변수로 사용
연결 한계	폐교 493 행, 신설 263 행, 4 개년 모두 있는 학과 9,369 개	연결 불가 학과 제외 → 생존 편향을 한계로 명시

※ 위 수치는 계획서 작성 중 pandas 로 직접 계산한 값이며 정제 노트북에서 재실행해 확정한다. 집단별 중도탈락률(결과)은 가설을 세우기 전에 보지 않았다. 개인 식별 정보 없음, 기관 공시 집계 자료.

III. 분석 설계

구분	사전 고정 내용
분석 단위와 범위	(학교, 학과) × 공시연도 쌍. 직전연도(t−1) 정보로 당해(t)를 예측. 직전연도 재적 30 명 이상, 비율 유효, 폐교 및 신설 제외
설명 변수	전년도 중도탈락학생비율, 전년도 재적학생(로그), 전년도 사유 구성비, 설립유형, 소재지유형, 표준분류 대계열, 주야간구분, 학교종류. 당해 연도의 계, 사유, 비율은 쓰지 않는다(누수 방지)
학습/테스트	시간 분리: 학습 t=2024, 2025, 테스트 t=2026. 같은 학과가 양쪽에 섞이는 무작위 분할은 쓰지 않는다. 75 백분위 컷은 학습 데이터로만 계산 (random_state=42)
모델과 판정	로지스틱 회귀. 정확도, 정밀도, 재현율, AUC, 혼동행렬을 기준선과 한 표로 보고. 기준선 ②가 지원하는 학과 수(k)와 같은 k 를 모델이 고를 때의 적중률로 비교
민감도	① 최소 재적 10, 30, 50 명 ② 임계값 0.5 vs 지원 가능 학과 수 기준(비용 가정 명시)
시각화 3 종	① 탈락 인원(명, 절대) × 탈락률(%, 비중) 산점도: 소규모 학과 비율 과대 확인(교차 = 산점도) ② 계열, 설립유형, 지역별 고위험 비율 막대: 지원 대상 기준 ③ 모델 vs 기준선 적중률과 임계값 비교

IV. 세부 가설과 판정 규칙

가설	예상	맞음 / 틀림 판정 (사전 고정)
H1 구조	비수도권, 사립, 소규모(재적 하위 25%) 학과는 고위험일 가능성이 높다	다른 변수를 고정한 오즈비 > 1 이고 95% 신뢰구간이 1 을 포함하지 않으면 맞음. 아니면 해당 배분 기준 기각
H2 사유	탈락 인원의 과반은 자퇴, 미등록, 미복학이다	세 사유의 합 ÷ 계 ≥ 50%(전체 및 계열별)이면 맞음 → 성적 경고 대응보다 이탈 초기 접점(상담, 복학 안내) 중심 권고
H3 예측	전년도 비율이 가장 강한 신호이며 구조 정보의 추가 개선은 작다	같은 k 에서 적중률 개선 5%p 미만이면 맞음 → '전년도 고위험 학과 우선 지원' 권고. 5%p 이상이면 모델 선별 권고
H4 한국외대	소규모 어문학과군(기타유럽어, 기타아시아어 문학 소계열)의 중도탈락률이 한국외대 내 다른 학과와 전국 동일 소계열보다 높다	공시 2024~2026 합산 비율(탈락 합계 ÷ 재적 합계)이 두 비교군 모두보다 높고, 학과 단위 부트스트랩 95% 구간의 차이 하한이 0 초과면 맞음. 한쪽만이면 부분, 둘 다 아니면 기각

※ 5%p 기준은 팀이 정한 값이므로 민감도 표(최소 재적, 임계값별 개선 폭)로 기준에 따라 결론이 뒤집히는지 함께 보고한다.

V. 한계와 진행 계획

□ 학과 단위 집계 통계라 학생 개인의 이탈 요인(경제, 정서, 진로)을 담지 못하며, 결과는 상관이지 인과가 아니다.

□ 테스트는 공시 2026 한 해뿐이다. 4 개년 중 쌍을 이루는 시점은 3 개이고, 다른 해로의 일반화는 보장하지 못한다.

□ 폐지, 통폐합, 신설 학과가 연결에서 빠져 생존 편향이 생길 수 있고, 소규모 학과는 비율이 크게 흔들려 최소 재적 기준에 결과가 좌우될 수 있다.

□ 한국외대는 학부 및 전공 개편으로 학과코드가 해마다 크게 바뀌고(2026 공시 신규 38 개, 소멸 24 개), 전국 비교군도 9~10 개교 32~44 개 학과로 작으며, 서울캠퍼스와 글로벌캠퍼스는 데이터에서 구분되지 않는다. 그래서 H4 는 학과 연결 없이 군 단위로 비교하고 '존폐 위기' 여부는 이 데이터로 판단하지 않는다.

□ 미등록, 미복학 등 공시 항목의 정의와 2023 년 이후 결측 증가의 원인은 데이터만으로 확인할 수 없어 대학알리미 공시 지침을 확인해야 한다. 전국 패널에서 배운 규칙은 개별 대학 적용 전 자교 자료로 재검증한다.

시점	할 일	남기는 것
11/8 → 11/13	제안서 제출 → 피드백 반영(주제, 데이터 조정)	수정된 질문과 가설, 수집 기록표
수집 및 정제	원자료 재다운로드, 행/열 수 대조, 품질 6 대 기준 진단, 정제	정제 로그(처리, 건수, 근거, 영향), 기대값 assert
분석 및 예측	EDA, 로지스틱 회귀, 기준선 및 민감도 비교	기준선 비교표, 재실행 가능한 노트북
발표 전날 23:59	슬라이드 PDF(본문 10 장), 원자료, 로그 3 종, 기여도표 제출	다른 계정 재실행 확인