다음 학년도 중도탈락 고위험 학과는 어디인가

학업지속 지원 대상 학과 선정을 위한 학과별 중도탈락 패널 분석 · 예측

가설 A 전국 구조

사립 · 비수도권 학과는 고위험이 많은가

→

가설 B 한국외대

비주류 외국어 학과군이 우선 지원 대상인가

교육부 대학알리미 중도탈락 학생 현황 (공공데이터포털 15164570)

빅데이터분석 14조　정승엽, 박유진, 신효주

분석 자료

56,340행	대학알리미 학과별 공시 2023~2026
210개교	일반 대학 주간 학과 50,081행
23,114쌍	전년 → 당해 분석 표본

의사결정과 질문

학사종합지원센터는 내년 학업지속 지원을 어느 학과에 먼저 배치해야 하는가

1 누가

한국외국어대학교 학사종합지원센터

보조: 입학처

2 무엇을

다음 학년도 학업지속 지원의 우선 배치 학과

상담 · 학습지원 · 복학 안내

3 어떻게 판단

중도탈락 고위험 = 탈락률 상위 25%

학습기간 75백분위 7.91% 이상

질문 ① 구조

가설 A

전국 일반 대학 학과 중 어떤 설립유형 · 지역에서 고위험이 많은가

질문 ② 우선 지원 대상

가설 B

그중 한국외대에서는 어떤 학과군이 고위험인가

미리 정한 다른 경로

질문 ②의 답이 '아니다'이면
이탈이 아니라 모집의 문제
→ 입학처로 넘겨 다시 정의한다

범위 전국 일반 대학 주간 학과(사이버 · 산업 · 교육대 · 야간 · 계약학과 제외). 학습 t = 2024 · 2025 공시, 테스트 t = 2026 공시

출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 판정 규칙: 00_문제정의_가설.md

가설과 판정 규칙

결과를 보기 전에 판정 규칙과 반대 결과의 처리까지 정해 두었다

가설 A 전국 구조

사립 · 비수도권 학과는 국공립 · 수도권 학과보다 고위험 가능성이 높다

판정 규칙

- 대계열 · 전년도 재적 규모를 통제한 로지스틱 회귀
- 두 오즈비 > 1 이고 95% 구간이 1을 넘으면 맞음
- 하나만이면 부분 맞음, 둘 다 아니면 기각

반대 결과가 나오면 기각된 기준은 지원 배분 근거로 쓰지 않는다

가설 B 한국외대

비주류 외국어 학과군(기타유럽어 · 기타아시아어 소계열)은 교내 다른 학과보다 탈락률이 높다

판정 규칙

- 공시 2024~2026 합산 탈락률(탈락 합계 ÷ 재적 합계)
- 학과 단위 부트스트랩으로 차이의 95% 구간
- 구간 하한 > 0 이면 맞음, 아니면 기각

반대 결과가 나오면 기각이면 '모집(입학처)' 문제로 재정의한다

예측 절 두 가설 안에서 '작년 고위험 학과 수(k)만큼 지원하면 몇 곳을 맞히나'를 작년 명단과 비교한다 — 판정 임계값 없이 그대로 보고

고정: git 태그 hypotheses-locked(11/8) → hypotheses-locked-v2 · v3(11/11, 결과 확인 전, 노트북 출력 0개 상태에서 커밋)

데이터 · 범위와 함정

비율 칸만 믿으면 틀린다 — 분모(재적)와 분류부터 확인해야 하는 데이터

자료와 범위

교육부 대학알리미 중도탈락 학생 현황
학과별 · 공시 2023~2026 · 32개 열
공공데이터포털 15164570 · 공공누리 제1유형

56,340행

원자료 전체 (학과 × 공시연도)

↓

50,081행

일반 대학 주간 학과 · 210개교 (88.9%)

제외: 사이버 · 산업 · 교육 · 방송통신대, 야간 · 원격, 계약학과 · 산업체위탁, 폐교 → 민감도 분석에만 사용

1 결측이 해마다 다르다

탈락률 결측 2023년 0.8% → 2024년 14.8% · 2026년 15.2%

처리 보정하지 않고 표본에서 제외

2 재적 0인데 탈락률 0%

1,697행 — 탈락자가 있어도 0%로 기록

처리 재적 > 0 인 행만 y로 사용

3 탈락률 100% 초과

172행, 그중 87.2%가 재적 5명 이하

처리 값은 그대로, 전년도 재적 30명 이상만 분석

4 분류가 학교마다 갈린다

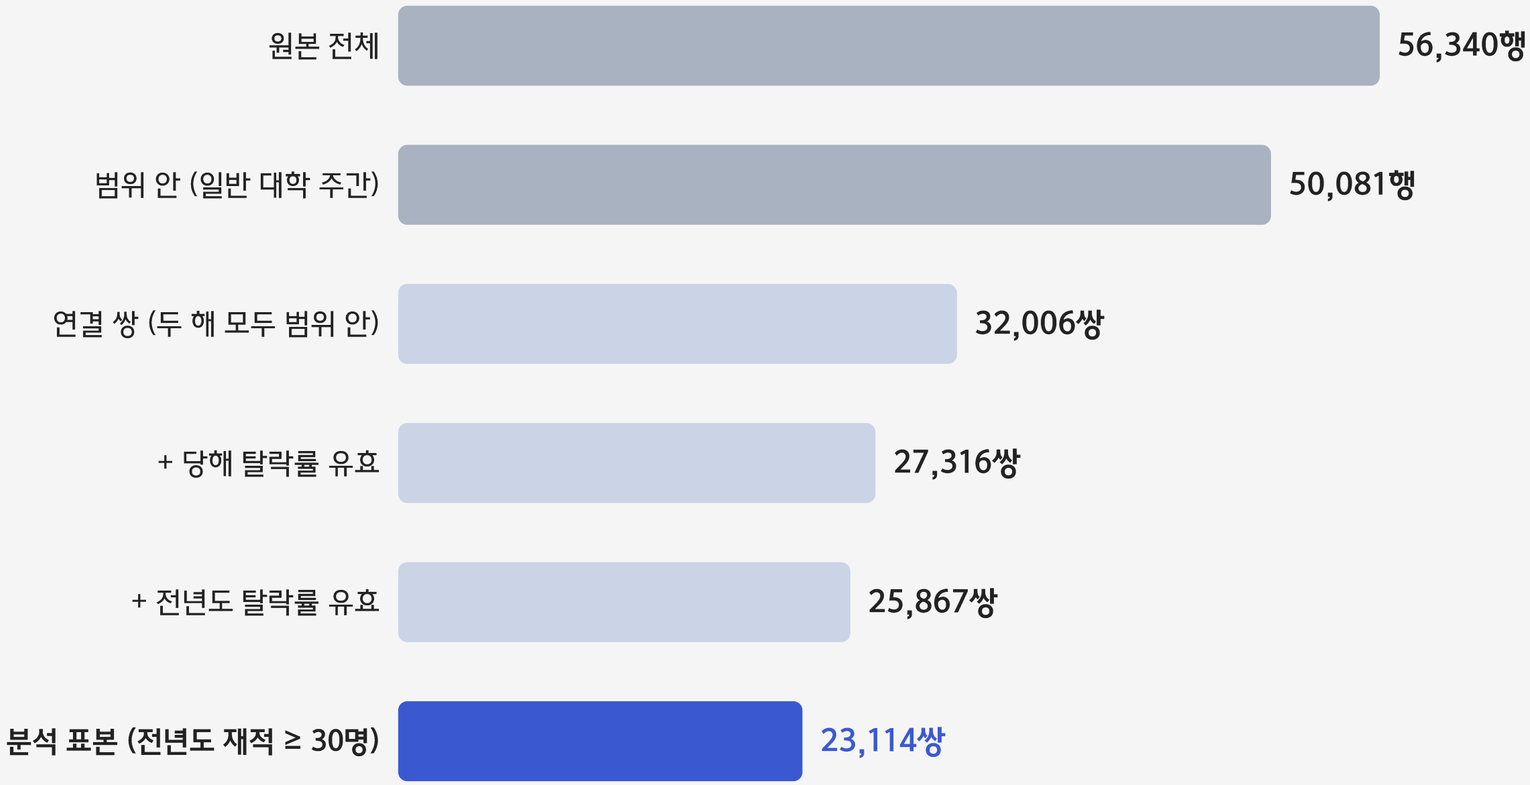
5개교 이상 같은 학과명 508개 중 232개(45.7%)가 소계열이 다름

처리 재분류하지 않고 데이터 분류 그대로 + 한계로 공개

출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §③ 셀 s3-01·s3-03·s3-05·s3-16 · 정제로그 표 4

정제: 행은 지우지 않고 표시만

원본 56,340행에서 23,114쌍으로 — 단계마다 남은 수와 이유를 기록했다



검증 흔적

0행
지운 행 (표시 후 제외)

0건
y(탈락률)에 한 보정

15,608 / 7,506
학습(2024·25) / 테스트(2026) 쌍

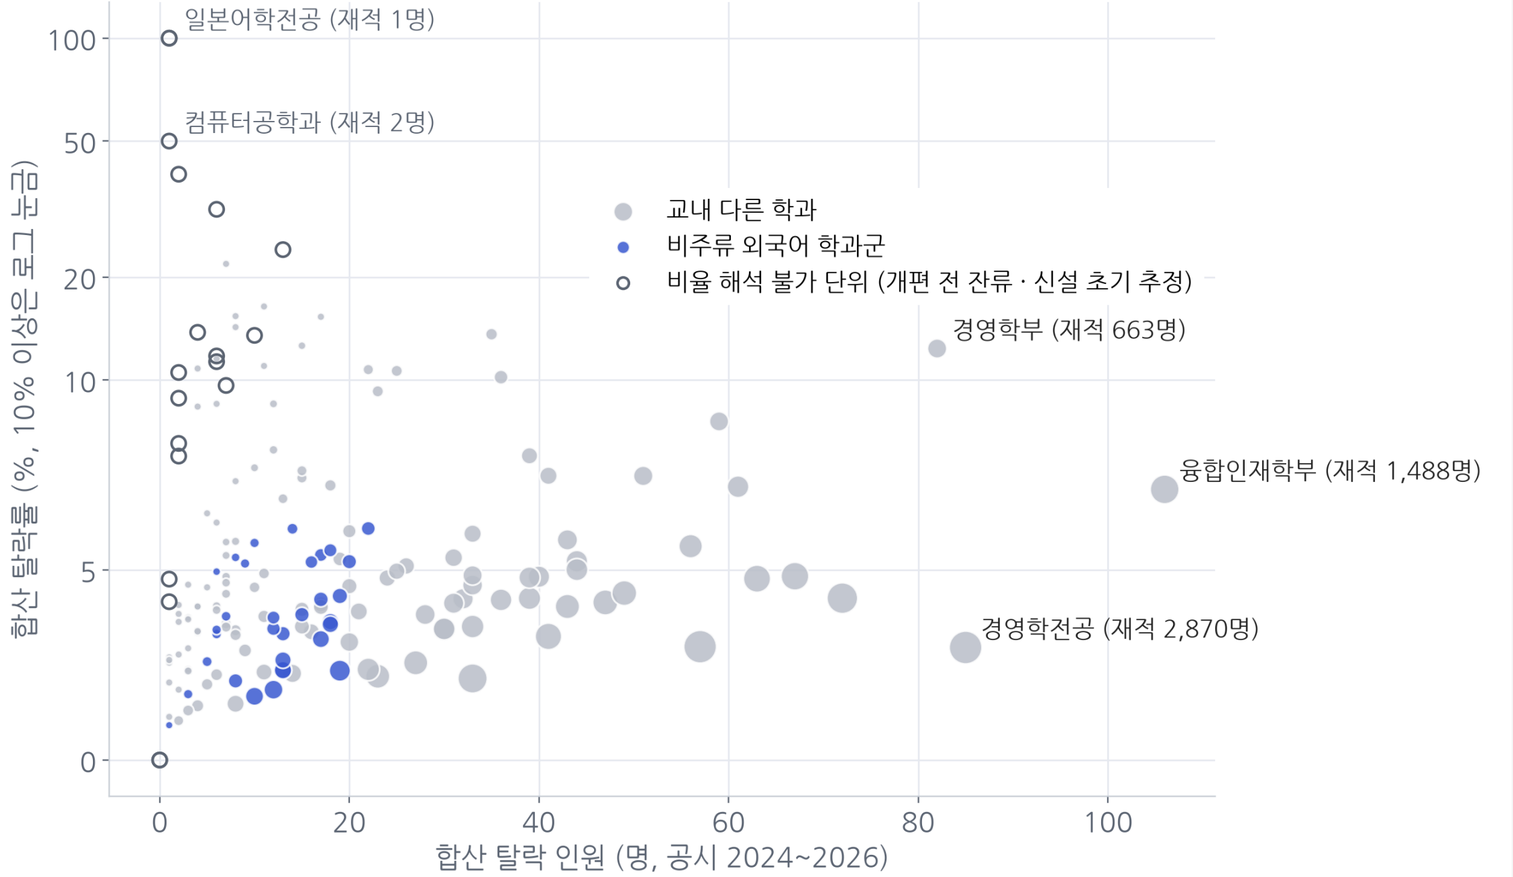
0.01%p
공시 비율 vs 계÷재적 최대 차이

읽는 법 막대 = 단계별로 남은 수. 연결 이후는 '전년 → 당해' 쌍 단위. 빠진 행의 사유와 건수는 정제로그 표 4 · 5에 모두 공개

출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §③ 셀 s3-16·s3-18·s3-19·s3-20 · 정제로그 표 1·4·5

탈락 인원 × 탈락률: 비율만 보면 생기는 착시

탈락률 상위 10과 탈락 인원 상위 10은 거의 겹치지 않는다 (원판정 0곳 · 해석 보정 1곳) → 인원과 비율을 함께 본다



0곳 → 1곳

비율 상위 10 ∩ 인원 상위 10 (원판정 → 해석 보정)

왜 보정했나 원판정 탈락률 상위 10 중 6곳이 '재적 1명 · 탈락 1명' 같은 단위. 재적이 줄다 사라지고 사유가 미복학 → 개편 전 잔류 5곳, 신설 초기 1곳으로 추정

해석 보정판 탈락률 상위 3 (연평균 재적 ≥ 30명)

Culture & Technology융합대학 21.9% (재적 32명)
공과계열 16.4% (재적 67명)
자연과학대학 15.4% (재적 52명)

그래서 지원 명단은 재적 30명 이상에서 고르고 탈락 인원(명)을 함께 표시한다. 보정판 상위는 통합모집 · 계열 단위(→ 슬라이드 9)

읽는 법 점 = 한국외대 학과(공시 2024~2026 합산), 크기 = 재적, 파랑 = 비주류 외국어 학과군, 빈 원 = 비율 해석 불가 단위(연평균 재적 30명 미만). 세로축 10% 이상 로그 눈금

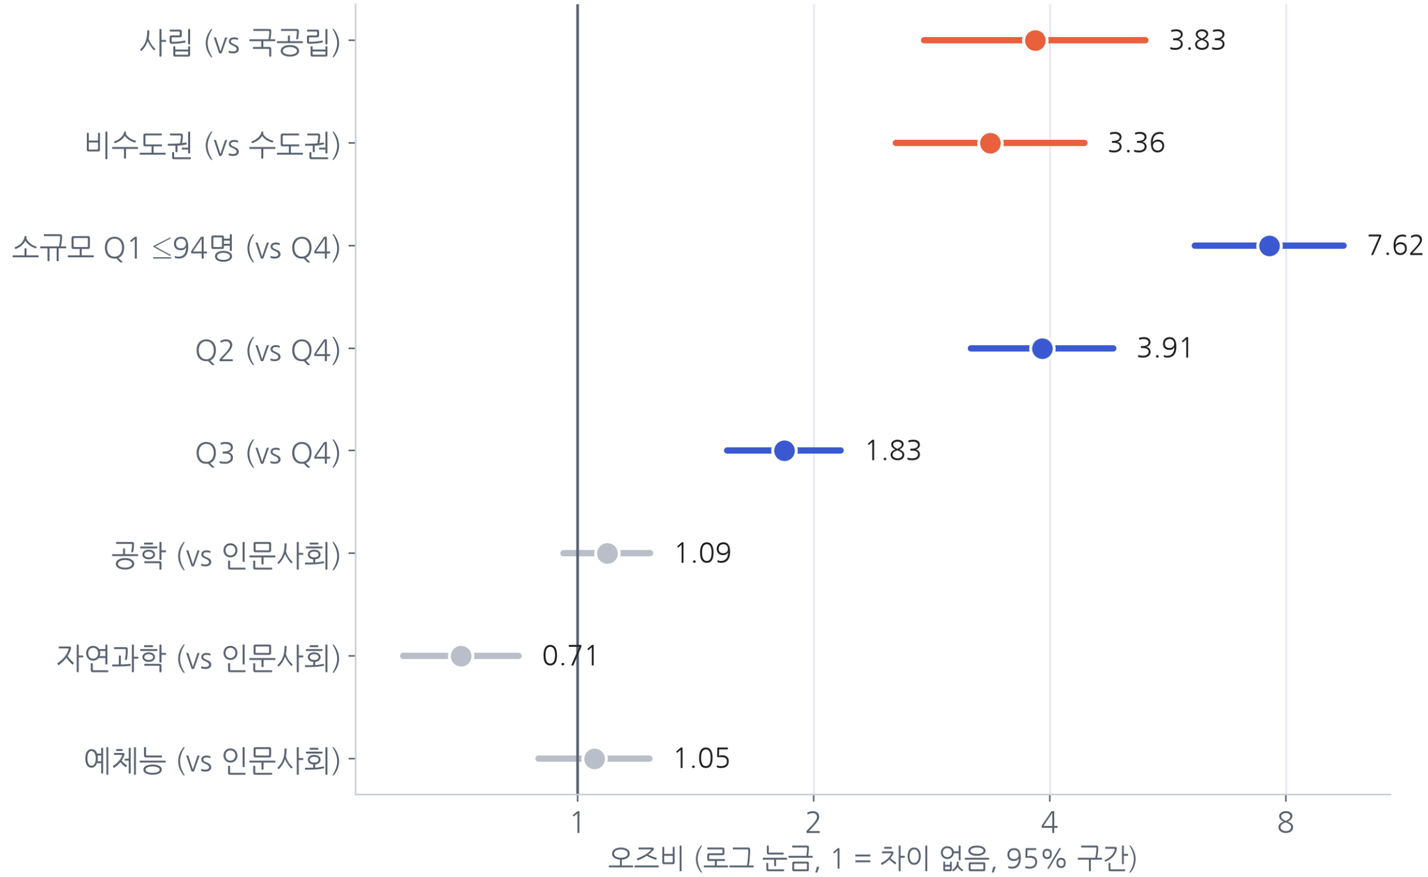
출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §⑤ 셀 s5-c10 · 부록 E 셀 sE-01(원판정) · sE-02(해석 보정) (필수 차트 ① 교차 산점도)

가설 A: 사립 · 비수도권

판정 맞음

가설 A 전국 구조

계열 · 규모를 통제해도 사립 3.8배, 비수도권 3.4배 — 가장 큰 신호는 소규모(7.6배)



설립유형 × 지역의 고위험 비율

국공립 · 수도권	국공립 · 비수도권
7.5%	15.1%
905쌍	5,035쌍

사립 · 수도권	사립 · 비수도권
13.9%	38.8%
7,303쌍	9,871쌍

판정 사립 3.83 [2.77, 5.30], 비수도권 3.36 [2.55, 4.43] — 둘 다 1을 넘어 **맞음**. 학습 기간만, 의학계열 제외로 다시 해도 같은 판정

읽는 법 오즈비 1 = 차이 없음. 구간은 같은 학교 학과끼리 묶은 95% 구간(학교 207개 군집). 상관이지 인과가 아니다

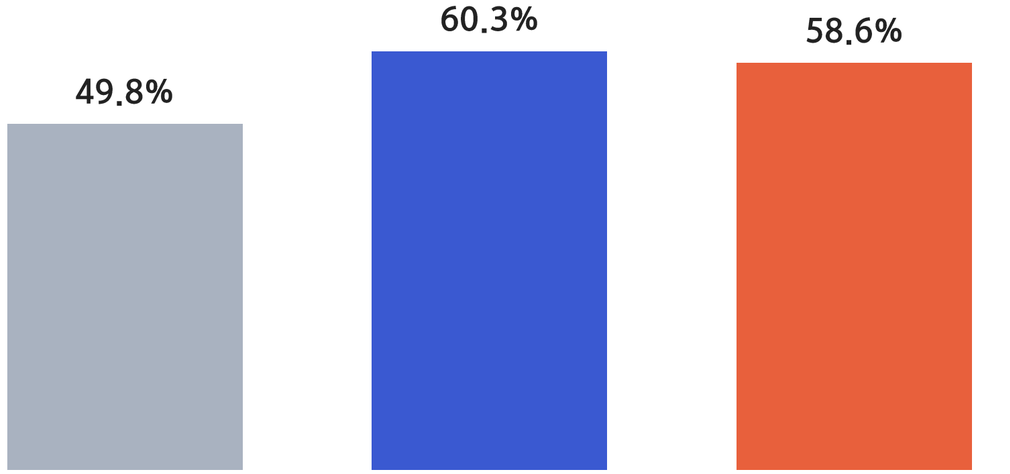
출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §④ 셀 s4-03·s4-05 · 분석 표본 23,114쌍

예측: 작년 명단보다 나은가

예측 절 모델 vs 기준선

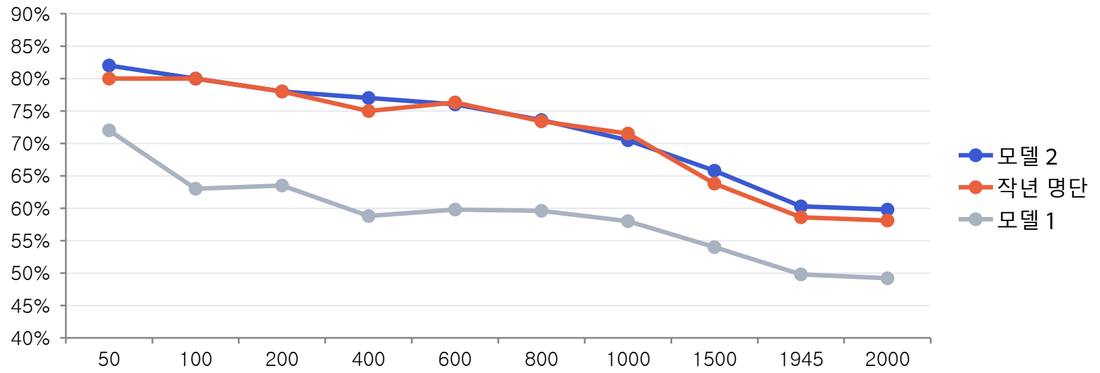
작년 고위험 학과 수(1,945개)만큼 지원하면 모델 2가 +1.7%p — 개선은 작고, 가장 강한 신호는 전년도 탈락률

같은 1,945개를 지원했을 때 정밀도



맞힌 학과: 모델 1 969 · 모델 2 1,173 · 작년 명단 1,140 | 무작위로 고르면 23.6%

지원 학과 수 k를 바꾸면



기준을 바꿔도 결론은 같다 (민감도)

조건	가설 A	모델 2 – 작년 명단
기본 (재적≥30, 상위 25%)	맞음	+1.7%p
③ 재적≥10	맞음	+3.0%p
③ 재적≥50	맞음	+1.8%p
④ 고위험 상위 20%	맞음	+1.7%p
④ 고위험 상위 30%	맞음	+1.9%p
② 전체 표본(사이버·산업·야간 등 포함)	맞음	+1.5%p

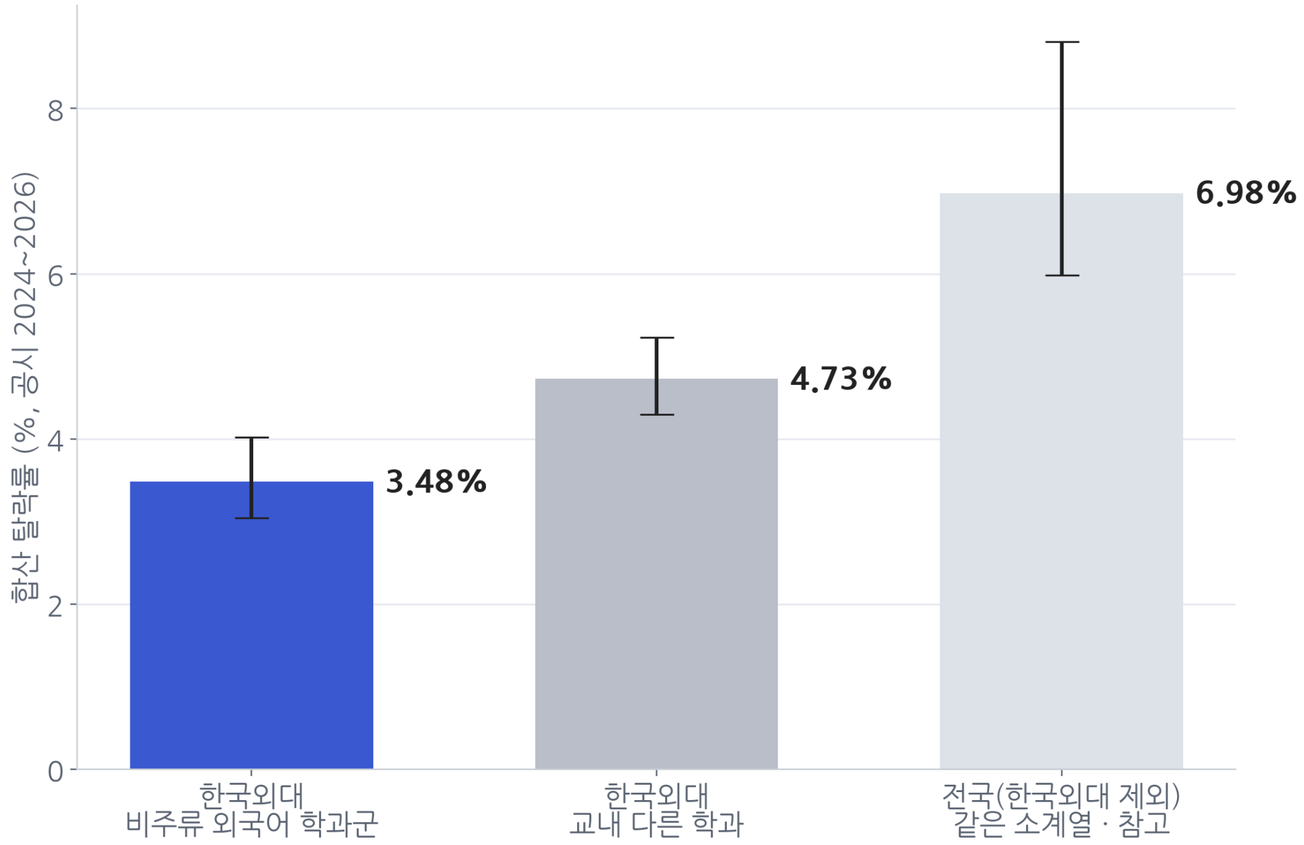
읽는 법 정밀도 = 지원한 학과 중 실제로 고위험이었던 비율. 재현율(실제 고위험 중 명단에 든 비율)은 모델 2 66.1% vs 작년 명단 64.3%

출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §④ 셀 s4-07·s4-14 · 테스트 = 공시 2026 7,506쌍 (필수 차트 ③)

가설 B: 한국외대 비주류 외국어 학과군

판정 기각 | 가설 B 한국외대

비주류 외국어 학과군은 오히려 1.25%p 낮다 — 위험은 전공을 정하기 전 단위에 몰려 있다



판정 차이 -1.25%p, 95% 구간 [-1.92, -0.56] — 하한이 0보다 작아 **기각**

규칙대로 어문 학과군은 이탈 지원의 우선 대상이 아니다 → '모집(입학처)' 문제로 재정의

공시 2027 우선 지원 후보 상위 20곳 (모델 2)

13곳 통합모집 · 계열 · 자유전공 등 전공 배정 전 단위 **0곳** 비주류 외국어

후보	재적	탈락률	점수
Culture & Technology융합대학[통합모집]	32명	21.9%	0.92
공과계열	67명	16.4%	0.77
글로벌자유전공학부	37명	16.2%	0.76
핵심외국어계열	56명	14.3%	0.68

사유 탈락의 97.4%가 자퇴(그 밖 75.6%) → 반수 · 초기 부적응 추정

참고 전국(한국외대 제외) 같은 소계열 8개교와 비교만 했다(가설 아님): 한국외대가 3.50%p 낮음 → 미리 정한 문구 "한국외대가 더 낮음"

출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §④ 셀 s4-10·s4-12·s4-13 · §⑤ 셀 s5-c09 (필수 차트 ②)

권고와 근거

작년 명단을 기본으로, 전공 배정 전 단위를 먼저 — 어문 학과군은 입학처의 모집 문제로

1 학사종합지원센터

내년 지원 명단 = 작년 고위험 학과 + 모델 점수로 보완

근거 모델 2 60.3% vs 작년 명단 58.6% (+1.7%p) — 차이가 작아 작년 명단이 기본

방법 재적 30명 이상에서 고르고, 탈락 인원(명)을 함께 표시 (비율 상위 10 ∩ 인원 상위 10 = 0곳)

출처 셀 s4-07 · sE-01

2 학사종합지원센터

통합모집 · 계열 · 자유전공 단위를 먼저 점검

근거 공시 2027 후보 상위 20곳 중 13곳이 전공 배정 전 단위, 탈락의 97.4%가 자퇴(반수 · 초기 부적응 추정)

방법 1학년 1학기 적응 상담과 전공 안내를 앞당기고, 입학처와 반수 이탈 여부를 함께 확인

출처 셀 s4-13 · s4-13b

3 입학처

어문 학과군은 '이탈'이 아니라 '모집'으로 재정의

근거 가설 B 기각: 교내보다 1.25%p 낮고 전국 같은 분야보다도 낮다

방법 지원율 · 충원율 자료로 다음 분석 (이 데이터에는 없음)

출처 셀 s4-10 · s4-12

쓰지 않는 근거 가설 A(사립 · 비수도권)는 맞았지만, 한국외대 안에서는 모든 학과가 같은 설립유형 · 지역이라 학과 배분 기준이 되지 못한다 — 전국 맥락으로만 쓴다

출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §④ 셀 s4-15 (판정 요약)

한계와 믿기 어려운 이유

이 결과로 말할 수 없는 것 — 원인, 내년의 성능, 학생 한 명의 이탈 이유

한계 3가지

1. **테스트는 공시 2026 한 해뿐**
   +1.7%p가 내년에도 유지된다는 보장이 없다

2. **학과 단위 집계, 상관 ≠ 인과**
   사립 · 비수도권 '때문에' 탈락한다고 말할 수 없다. 학생 구성 등은 관측되지 않았다

3. **생존 편향과 공시 변화**
   연결되지 않은 학과 5,399행(한국외대 61개)이 빠졌고, 2024년부터 결측이 늘었다

믿기 어려운 이유

한국외대 예측은 작은 표본
검증 학과 94개, k = 16: 모델 2 37.5% vs 작년 명단 43.8% — 우연에 크게 흔들린다

분류는 학교 신고에 의존
같은 학과명도 학교마다 계열이 갈린다. 재분류하지 않고 데이터 분류를 그대로 썼다

'비인기 · 존폐 위기'는 판단 불가
지원율 · 충원율 · 모집정원이 없다. 그래서 B 기각 뒤의 모집 문제는 이 자료로 답할 수 없다

작은 단위의 비율은 개편의 흔적
'재적 1명 · 탈락 1명 = 100%'처럼 개편 중 단위는 비율이 위험을 뜻하지 않는다 → 연평균 재적 30명 미만 19개는 비율 순위에서 뺐다(추정 근거: 재적 감소 · 소멸, 미복학)

그래도 쓸 수 있는 것 기준 6가지를 바꿔도 A · B 판정과 '모델 ≈ 작년 명단' 결론은 뒤집히지 않았다(민감도). 노트북은 처음부터 다시 돌려 같은 숫자가 나온다

출처: 교육부 대학알리미 중도탈락 학생 현황(공공데이터포털 15164570, 공공누리 제1유형) · 노트북 §④ 셀 s4-13·s4-14 · 정제로그 표 4

부록 A. 재현성 확인

노트북을 새 커널에서 처음부터 실행해 같은 숫자가 나오는지 확인했다

확인 항목	정승엽 (로컬)	박유진	신효주
에러 없이 완주	O	[팀 입력]	[팀 입력]
원본 행 × 열	56,340 × 32		
범위 안 행 수 / 분석 표본 쌍 수	50,081 / 23,114		
가설 A 사립 · 비수도권 오즈비	3.83 · 3.36		
가설 B 차이와 95% 구간	-1.25%p [-1.92, -0.56]		
모델 2 정밀도 / 작년 명단	60.3% / 58.6%		
실행 환경	Python 3.13.14, pandas 3.0.6		

링크 Colab(팀 정본) colab.research.google.com/drive/1JCE1qZSWkixXybo86cDwFJpl4_n-Tbmc · GitHub github.com/202103116-stack/university-dropout-risk-analysis

logs/재현성_확인표.md · 실행 2026-11-12 01:04

부록 B. 기여도표

안내문 5단계별 담당자와 검토자

단계	세부 작업	담당자	검토자
① 문제 정의	의사결정 질문, 가설 A · B, 판정 규칙 고정	[팀 입력]	[팀 입력]
② 수집	원자료, 출처 · 이용 조건, 범위 정의, 측정 척도	[팀 입력]	[팀 입력]
③ 정제	품질 6대 기준 진단, 범위 확정, 정제 로그	[팀 입력]	[팀 입력]
④ 분석	EDA, 모델, 기준선, 민감도, 가설 판정	[팀 입력]	[팀 입력]
⑤ 발표	차트 3종, 권고 · 근거 · 한계, 슬라이드, 발표	[팀 입력]	[팀 입력]
공통	AI 활용 로그, 재현성 확인	[팀 입력]	[팀 입력]

부록 C. AI 활용 로그 요약

AI가 틀린 진술은 원문과 재측정으로 바로잡고, 모든 수치는 셀 출력과 대조했다

AI 진술 · 제안	검증 방법	결과
안내문이 '제안서 1쪽'을 요구한다	안내 PDF 원문 직접 확인	**수정: 분량 제한 없음**
B 대상군에 국제지역학 포함	학과명 단위로 소계열 갈림 재측정	**수정: 민감도로만 사용**
전국 같은 분야보다 한국외대가 높을 것	근거 없는 방향 가정이라는 사용자 지적	**수정: 판정에서 빼고 결과 문구만 고정**
계획서 기준값 '재계산 불일치 68행'	노트북 재계산(최대 차이 0.005%p)	**기록: 재현 안 됨 [확인 필요]**
정제 · 분석 · 시각화 코드	assert, 누수 점검, 시드 4개, 그림 직접 확인	**채택**

제출물: 14조_AI활용로그.pdf · 전체 기록 logs/AI활용기록.md

부록 D. 범위 제외 내역과 민감도

어떤 조건으로 몇 행이 빠졌는지, 기준을 바꾸면 결론이 어떻게 되는지

범위 조건	단독 제외	순차 제외
학교종류 == '대학교'	3,595	3,595
주야간구분 == '주간'	3,748	1,626
학과특성 == '일반과정'	1,249	575
학교상태 != '폐교'	493	463

조건	쌍 수	A 판정	사립 OR	비수도권 OR	모델 2	작년 명단
기본 (재적≥30, 상위 25%)	23,114	맞음	3.83	3.36	60.3%	58.6%
③ 재적≥10	25,008	맞음	3.97	3.16	62.3%	59.4%
③ 재적≥50	21,193	맞음	3.72	3.63	60.6%	58.8%
④ 고위험 상위 20%	23,114	맞음	4.23	3.43	56.1%	54.4%
④ 고위험 상위 30%	23,114	맞음	3.54	3.38	63.5%	61.5%
② 전체 표본(사이버·산업·야간 등 포함)	25,836	맞음	3.40	1.80	63.2%	61.7%

민감도 ① B 대상군에 국제지역학 소계열을 더해도 차이 -1.25%p [-1.93, -0.56] → 기각. 임계값 0.5로 고르면 1,335곳, 정밀도 67.3%

노트북 §③ 셀 s3-16 · §④ 셀 s4-14 · 정제로그 표 4 · 5 · 6

부록 E. 보조 분석 R1: 비율 상위 vs 인원 상위

한국외대 공시 2024~2026 합산 — 두 상위 10 목록의 교집합 0곳 (가설 판정이 아닌 보조 분석)

탈락률 상위 10

학과	탈락(명)	재적(명)	탈락률
일본어학전공	1	1	**100.0%**
일본문학전공	1	1	**100.0%**
컴퓨터공학과	1	2	**50.0%**
영어전공	2	5	**40.0%**
프랑스어과	6	19	**31.6%**
Finance & AI융합전공	13	54	**24.1%**
Culture & Technology융합대학[통합모집]	7	32	**21.9%**
공과계열	11	67	**16.4%**
자연과학대학[통합모집]	8	52	**15.4%**
Language & AI융합학부	17	111	**15.3%**

탈락 인원 상위 10

학과	탈락(명)	재적(명)	탈락률
융합인재학부	**106**	1,488	7.1%
경영학전공	**85**	2,870	3.0%
경영학부	**82**	663	12.4%
독일어과	**72**	1,690	4.3%
영미문학.문화학과	**67**	1,385	4.8%
ELLT학과	**63**	1,320	4.8%
화학과	**61**	848	7.2%
전자물리학과	**59**	662	8.9%
스페인어과	**57**	1,911	3.0%
컴퓨터공학전공	**56**	995	5.6%

노트북 부록 E 셀 sE-01 · 판정 규칙: 00_문제정의_가설.md 10절 (사전 규칙 그대로 센 원판정)

부록 E-2. R1 해석 보정: 비율을 해석할 수 없는 단위

원판정 탈락률 상위 10 중 6곳은 개편 · 신설 단위 — 같은 최소 재적 기준(연평균 30명)으로 다시 세면 교집합 1곳

원판정 상위 10	연평균 재적	해석 (근거)
일본어학전공	1.0	개편 전 잔류 추정(재적 감소·소멸, 미복학 100%)
일본문학전공	1.0	개편 전 잔류 추정(재적 감소·소멸, 미복학 100%)
컴퓨터공학과	2.0	개편 전 잔류 추정(재적 감소·소멸, 미복학 100%)
영어전공	2.5	개편 전 잔류 추정(재적 감소·소멸, 미복학 100%)
프랑스어과	9.5	개편 전 잔류 추정(재적 감소·소멸, 미복학 83%)
Finance & AI융합전공	27.0	신설·개편 초기 추정(첫 공시 이후 재적이 적음)
Culture & Technology융합대학[통합모집]	32.0	해석 가능
공과계열	67.0	해석 가능
자연과학대학[통합모집]	52.0	해석 가능
Language & AI융합학부	55.5	해석 가능

보정판 상위 10	탈락(명)	재적(명)	탈락률
Culture & Technology융합대학[통합모집]	7	32	**21.9%**
공과계열	11	67	**16.4%**
자연과학대학[통합모집]	8	52	**15.4%**
Language & AI융합학부	17	111	**15.3%**
핵심외국어계열	8	56	**14.3%**
자유전공학부(글로벌)	35	257	**13.6%**
Language & Diplomacy학부	15	119	**12.6%**
경영학부	82	663	**12.4%**
국가전략언어계열	6	52	**11.5%**
자유전공학부(서울)	11	100	**11.0%**

규칙 재적(학년도 학적 보유자)과 탈락(그 1년간 떠난 수)은 같은 사람을 센다 → 1/1 = 남은 한 명이 떠남. 연평균 재적 30명 미만은 비율 순위에서만 빼고 행 · 인원 순위는 그대로 둔다

노트북 부록 E 셀 sE-02 · 원판정(sE-01)은 바꾸지 않음 · 추정은 학과코드의 재적 추이 · 소멸 · 탈락 사유(미복학)에 근거