빅데이터분석 팀 프로젝트 2 발표 자료

발표 대본

다음 학년도 중도탈락 고위험 학과는 어디인가

과 목	빅데이터분석
담당교수	박주원
조	14 조
팀 원	정승엽, 박유진, 신효주
자료 저장소	github.com/202103116-stack/university-dropout-risk-analysis
Colab 노트북	Colab(정승엽, 팀 정본) | Colab(박유진)

2026. 11. 12.

14 조

발표자: 신효주 (지난 발표자 박유진 제외 규칙 충족), 슬라이드: `slides/14 조_발표.pdf` (발표자 노트에 같은 대본)

규칙(안내문): 10 분 + Q&A 5 분, 9 분에 알림, 1 분 이상 초과 시 −5 점. 3 막 = 봤다 3 분 / 했다 4 분 / 그래서 3 분.

이 대본의 숫자는 노트북 출력(`data/processed/slides_data.json`)에서 자동으로 들어간다. 손으로 고치지 말고 `node slides/make_script_md.js` 로 다시 만든다.

추정 낭독 시간: **9:13** (한글 음절 기준 초당 4.2 음절 + 장마다 3 초 여유). 연습해 보고 길면 각 장의 '줄일 문장'부터 뺀다.

시간표

장	막	제목	목표	추정 낭독
1	표지	표지	0:10	0:18
2	봤다	의사결정과 질문	0:45	0:47
3	봤다	가설과 판정 규칙	0:50	0:52
4	봤다	데이터와 범위, 함정	1:15	1:10
5	했다	정제	0:50	0:48
6	했다	탈락 인원 × 탈락률	1:00	0:59
7	했다	가설 A	1:00	0:46
8	했다	예측	1:10	0:48
9	그래서	가설 B	1:15	1:12
10	그래서	권고와 근거	0:55	0:49
11	그래서	한계와 믿기 어려운 이유	0:50	0:44
		합계	**10:00**	**9:13**

막별 추정: 봤다 3:07, 했다 3:21, 그래서 2:45 (목표 3:00, 4:00, 3:00)

대본

1. 표지 (표지, 목표 0:10, 추정 0:18)

안녕하세요, 14 조 발표를 맡은 신효주입니다. 저희는 다음 학년도에 중도탈락 위험이 높은 학과가 어디인지, 대학알리미 공시 자료로 분석하고 예측했습니다.

팁: 인사는 짧게. 바로 다음 장으로.

2. 의사결정과 질문 (봤다, 목표 0:45, 추정 0:47)

이 분석은 한 기관의 결정을 돕기 위한 것입니다. 한국외대 학사종합지원센터가 내년에 상담과 학습지원, 복학 안내를 어느 학과에 먼저 배치할지입니다. 고위험은 탈락률 상위 25%, 즉 7.91% 이상인 학과로 정했습니다. 질문은 두 개입니다. 전국에서 어떤 유형의 학과가 위험한지, 그리고 한국외대 안에서는 어떤 학과군이 위험한지입니다. 한국외대 쪽 답이 "아니다"로 나오면, 문제가 이탈이 아니라 모집일 수 있어서 입학처로 넘기는 경로도 미리 정해 뒀습니다.

팁: '누가, 무엇을 결정하나'가 이 장의 전부. 상위 25% 기준을 꼭 말한다.

3. 가설과 판정 규칙 (봤다, 목표 0:50, 추정 0:52)

가설은 결과를 보기 전에 깃허브에 날짜를 남겨 고정했습니다. 가설 A 는 사립이거나 비수도권인 학과가 고위험일 가능성이 높다는 것입니다. 계열과 규모를 맞춘 회귀에서 두 효과가 모두 1 보다 크면 맞음입니다. 가설 B 는 한국외대의 비주류 외국어 학과군, 즉 기타 유럽어와 기타 아시아어 계열 학과가 교내 다른 학과보다 탈락률이 높다는 것입니다. 차이의 95% 구간이 0 보다 크면 맞음입니다. 틀렸을 때 무엇을 할지도 함께 정했습니다. 예측은 "작년 고위험 학과를 그대로 지원하는 것"보다 나은지로 평가합니다.

팁: '결과 전에 고정했다'를 강조 — 문제 정의 점수의 핵심.

4. 데이터와 범위, 함정 (봤다, 목표 1:15, 추정 1:10)

자료는 교육부 대학알리미의 학과별 중도탈락 공시, 4 년 치 56,340 행입니다. 사이버대나 야간처럼 학생 구성이 다른 과정은 빼고, 일반 대학 주간 학과 50,081 행, 210 개 학교를 봤습니다. 이 데이터에는 함정이 네 가지 있었습니다. 첫째, 2024 년 공시부터 탈락률 빈칸이 약 15%로 늘었습니다. 둘째, 재적이 0 명인데 탈락률이 0%로 적힌 행이 1,697 개 있었습니다. 떠난 학생이

있어도 0%로 적혀 있어서, 비율 칸만 믿으면 틀립니다. 셋째, 탈락률이 100%를 넘는 행은 대부분 재적 5 명 이하의 작은 학과였습니다. 넷째, 같은 이름의 학과도 학교마다 계열 분류가 달랐습니다. 그래서 값을 고치지 않고, 믿을 수 있는 행만 골라 쓰는 방식으로 처리했습니다.

> 팁: 숫자는 화면에 있으니 '무엇이 함정인지'만 또박또박. 여기까지 3 분.

5. 정제 (했다, 목표 0:50, 추정 0:48)

정제 원칙은 "지우지 않고 표시만 한다"입니다. 문제가 있는 행에는 표시만 하고 분석에서 뺐고, 단계마다 몇 개가 남았는지 기록했습니다. 학과마다 작년과 올해를 이어 붙인 뒤, 두 해 모두 탈락률이 정상이고 작년 재적이 30 명 이상인 23,114 쌍이 최종 분석 자료입니다. 2024 년과 2025 년으로 학습하고, 한 번도 보지 않은 2026 년으로 시험했습니다. 계획서에 적어 둔 숫자와 같은지 코드로 하나하나 대조했고, 모두 일치했습니다.

> 팁: '쌍' = 한 학과의 작년 정보 → 올해 결과 한 묶음.

6. 탈락 인원 × 탈락률 (했다, 목표 1:00, 추정 0:59)

필수 차트인 교차 산점도입니다. 점 하나가 한국외대 학과이고, 가로가 떠난 인원, 세로가 탈락률입니다. 처음 정한 규칙대로 세면 탈락률 1 위는 재적 1 명 중 1 명이 떠난 100% 단위였습니다. 재적과 탈락은 같은 학생을 세기 때문에, 남아 있던 한 명이 떠났다는 뜻입니다. 재적이 줄다가 사라지고 사유가 모두 미복학이라, 학과 개편 전 옛 전공에 남은 학생으로 추정됩니다. 이런 단위 19 개는 그림에서 빼고 다시 셌는데, 그래도 탈락률 상위 10 곳과 탈락 인원 상위 10 곳은 1 곳만 겹쳤습니다. 그래서 지원 학과를 비율 하나로 고르면 안 되고, 떠난 인원을 같이 봐야 합니다.

> 팁: 그림에는 해석 가능한 단위만 있다. 뺀 단위와 근거는 부록 E-2(질문 나오면 넘겨서 보여 준다).

7. 가설 A (했다, 목표 1:00, 추정 0:46)

가설 A 입니다. 사립이면서 비수도권인 학과는 38.8%가 고위험이었고, 국공립 수도권은 7.5%였습니다. 두 요인이 겹쳐 있어서 회귀로 따로 떼어 봤습니다. 계열과 규모를 맞춰도 사립은 3.8 배, 비수도권은 3.4 배였고, 둘 다 신뢰구간이 1 을 넘어 가설 A 는 맞았습니다. 다만 가장 큰 차이는 규모였습니다. 작은 학과는 큰 학과보다 고위험 오즈가 7.6 배였습니다. 이건 상관이지 원인이 아닙니다. 사립이라서 학생이 떠난다고 말할 수는 없습니다.

팁: '오즈비 3.8 배' = 다른 조건이 같을 때 고위험일 가능성이 약 네 배. '상관≠인과'는 반드시 말한다.

8. 예측 (했다, 목표 1:10, 추정 0:48)

예측입니다. 센터가 작년에 고위험이었던 학과 수만큼, 즉 1,945 개만 지원할 수 있다고 가정하고, 고른 학과 중 실제로 고위험이었던 비율을 비교했습니다. 학교 유형 같은 구조 정보만 쓴 모델 1 은 49.8%로, 작년 명단 58.6%보다 못했습니다. 작년 탈락률까지 넣은 모델 2 는 60.3%로, 작년 명단보다 1.7%p, 33 곳 더 맞혔습니다. 지원할 학과 수나 기준을 바꿔도 차이는 비슷했습니다. 가장 강한 신호는 작년 탈락률이고, 모델이 더해 주는 것은 작습니다.

팁: 기준선과 비교한 숫자를 꼭 같이 말한다(기준선 없는 정확도 금지). 이 장이 끝나면 약 7 분 — 시계를 한 번 본다.

9. 가설 B (그래서, 목표 1:15, 추정 1:12)

가설 B 입니다. 비주류 외국어 학과군의 탈락률은 3.48%로, 교내 다른 학과 4.73%보다 오히려 1.25%p 낮았습니다. 3 년 모두 낮았고 구간도 0 을 넘지 않아, 가설 B 는 틀렸습니다. 저희는 분석 전부터, 한국외대는 비주류 외국어 학과라도 스스로 지망해 온 학생이 많아 탈락률이 높지만은 않을 것이라고 예상했고, 가설 문서와 노트에 적어 두었습니다. 결과도 그 방향이었습니다. 다만 지망 여부는 데이터에 없어 확인하지는 못했습니다. 그 밖에 2026 년부터 생긴 외국어 계열 통합모집으로 일부 이탈이 학과 배정 전에 일어났을 수 있지만, 그 전 해에도 낮아서 일부만 설명합니다. 모델로 뽑은 내년 후보 20 곳 중 13 곳은 통합모집이나 계열 같은 1 학년 단위였고, 탈락의 97.4%가 자퇴였습니다.

팁: '틀렸다'를 분명히. 반대 결과 세 가지는 화면 아래 상자를 보며. 1 학년 단위는 비율로 다른 학과와 직접 비교하지 않는다고 질문받으면 답한다.

10. 권고와 근거 (그래서, 목표 0:55, 추정 0:49)

권고는 세 가지입니다. 첫째, 센터는 내년 지원 명단을 작년 고위험 학과로 시작하고 모델 점수로 보완합니다. 이때 재적 30 명 이상에서 고르고, 떠난 인원도 함께 봅니다. 둘째, 통합모집이나 자유전공 같은 1 학년 단위에서 1 학기 적응 상담과 전공 안내를 앞당깁니다. 셋째, 어문 학과군은 이탈 문제가 아니었으니, 입학처가 지원율과 충원율 같은 모집 지표로 다시 봅니다. 사립과 비수도권 결과는 맞았지만, 한국외대 안에서는 모든 학과가 같은 조건이라 배분 기준으로는 쓰지 않습니다.

팁: 권고마다 근거가 화면에 있으니 '근거는 화면 아래'라고 손짓만.

11. 한계와 믿기 어려운 이유 (그래서, 목표 0:50, 추정 0:44)

마지막으로 이 결과를 그대로 믿기 어려운 이유입니다. 시험은 2026 년 한 해뿐이라 내년에도 같다는 보장이 없습니다. 학과 단위 집계라 학생 한 명이 왜 떠났는지는 알 수 없고, 상관일 뿐 원인은 아닙니다. 학과가 없어지거나 코드가 바뀌면 분석에서 빠지는 문제도 있습니다. 한국외대만 따로 검증하면 94 개 학과뿐이라 우연에 크게 흔들립니다. 그래도 기준을 여섯 가지로 바꿔 봐도 결론은 뒤집히지 않았습니다. 감사합니다.

팁: 한계 3 종(테스트 1 년, 상관≠인과, 생존 편향)을 빠짐없이. 9 분 알림이 울렸으면 4 번째 문장(한국외대 검증)을 건너뛴다.

발표 전에 알아 둘 용어 (쉽게)

용어	한 줄 설명
재적	그 학년도에 학적이 있던 학생 수(재학 + 휴학). 탈락률의 분모
중도탈락	그 학년도(3 월~다음 해 2 월) 동안 학교를 떠난 학생. 자퇴, 미등록, 미복학 등 8 가지 사유
고위험	탈락률이 상위 25%(7.91% 이상)인 학과
쌍	한 학과의 '작년 정보 → 올해 결과' 한 묶음. 분석 데이터의 한 줄
기준선	모델 없이 하는 가장 쉬운 방법(작년 고위험 학과를 그대로 지원). 모델은 이걸 넘어야 의미가 있다
정밀도	지원한 학과 중 실제로 고위험이었던 비율. "지원이 헛되지 않았나"
재현율	실제 고위험 학과 중 지원 명단에 든 비율. "놓친 학과가 얼마나 되나"
오즈비	다른 조건이 같을 때 고위험 쪽으로 얼마나 기우는지. 1 이면 차이 없음
95% 구간	표본이 달라졌을 때 값이 움직일 범위. 1(오즈비)이나 0(차이)을 넘지 않아야 '확실한 차이'
부트스트랩	학과를 다시 뽑기를 2,000 번 반복해 차이가 얼마나 흔들리는지 재는 방법
민감도	기준(최소 재적, 고위험 컷, 범위)을 바꿔도 결론이 같은지 확인하는 것

예상 질문과 답 (발표하지 않는 팀원도 읽어 두기)

Q1. 왜 '상위 25%'를 고위험으로 정했나요?

지원 여력이 한정돼 있어 '전체의 4 분의 1'을 우선 대상으로 본 기준입니다. 결과 전에 고정했고, 20%와 30%로 바꿔도 결론이 같았습니다(민감도 ④, 부록 D).

Q2. 기준선이 뭐고, 왜 '작년 명단'인가요?

모델 없이도 할 수 있는 가장 쉬운 방법입니다. 작년에 고위험이던 학과를 올해도 지원하는 것. 모델이 이보다 못하면 쓸 이유가 없어서, 이걸 넘는지로 평가했습니다.

Q3. 모델이 1.7%p 밖에 안 좋은데 의미가 있나요?

개선이 작다는 게 결과입니다. 그래서 권고도 '작년 명단을 기본으로, 모델은 보완'으로 했습니다. 안내문에도 정확도가 낮아도 기준선 대비 차이와 이유를 정직하게 보고하면 된다고 돼 있습니다.

Q4. 오즈비 3.8 배는 확률이 3.8 배라는 뜻인가요?

정확히는 '오즈'(고위험일 확률 ÷ 아닐 확률)가 3.8 배라는 뜻입니다. 확률 자체가 그만큼 커지는 건 아니지만, 다른 조건이 같을 때 사립이 고위험 쪽으로 크게 기운다는 의미입니다.

Q5. 재적 1 명에 탈락 1 명이면 2 명 아닌가요?

같은 사람입니다. 재적은 그 학년도에 학적이 있던 학생, 탈락은 그 1 년 동안 떠난 학생이라 남아 있던 한 명이 떠났다는 뜻입니다. 개편 전 옛 전공에 남은 학생으로 추정돼, 연평균 재적 30 명 미만은 비율 순위에서 뺐습니다(부록 E-2).

Q6. 통합모집 단위 탈락은 세부 전공으로 옮긴 학생이 잡힌 것 아닌가요?

아닙니다. 탈락 사유에 '교내 이동'은 없고, 114 명 중 111 명이 자퇴입니다. 이동이 자퇴로 잡혔다면 자퇴가 재적의 대부분이어야 하는데 단위별 0.0~18.8%였고, 단위가 생긴 해에 학교 전체 탈락률은 오히려 4.85% → 4.22%로 내려갔습니다.

Q7. 1 학년만 있는 단위를 다른 학과와 비율로 비교해도 되나요?

직접 비교는 공정하지 않습니다. 다른 학과의 1 학년 탈락률은 학년별 자료가 없어 3.9~15.5% 범위로만 알 수 있고, 이 단위의 12.2%는 그 안에 있습니다. 그래서 '이 단위가 위험하다'가 아니라 '1 학년 초기 이탈이 여기 모여 보인다'고 말합니다.

Q8. 가설 B 는 왜 반대로 나왔나요?

세 가지로 봤습니다. ① 결과 전에 가설 문서(v2, 11/11 고정, git 태그로 확인 가능)에 "자발적으로 지망한 학생이 많아 낮거나 비슷할 수 있다"고 적었고, 분석 전 노트에도 "한국외대는 비주류 외국어 학과라도 스스로 지망해 온 학생이 많아 탈락률이 높지만은 않을 것"이라고 예상해 두었습니다. 결과가 그 방향이었습니다. 지망 여부는 데이터에 없어 확인은 못 했습니다 ②

2026 년부터 생긴 외국어 계열 통합모집으로 일부 이탈이 배정 전에 일어났을 수 있음(데이터로 일부 확인, 그 전 해는 설명 못 함) ③ 이중전공, 전과로 떠나지 않고 길을 바꿈(추정).

Q9. 왜 일반 대학 주간 학과만 봤나요?

사이버대, 야간, 계약학과는 성인, 원격 학습자가 많아 떠나는 이유가 다릅니다. 섞으면 '일반 대학의 학업지속'이라는 질문이 흐려집니다. 전체 표본으로도 따로 돌렸고 결론이 같았습니다(민감도 ②).

Q10. 결측은 어떻게 처리했나요?

채우지 않았습니다. 탈락률이 빈 행이나 재적 0 인 행은 표시만 하고 분석에서 뺐고, 몇 개를 왜 뺐는지 정제 로그에 모두 적었습니다. 탈락률 값 자체는 하나도 바꾸지 않았습니다.

Q11. 왜 무작위로 나누지 않고 연도로 나눴나요?

실제로는 작년 자료로 내년을 맞혀야 하니까요. 무작위로 섞으면 미래 정보가 학습에 들어가 성능이 부풀려집니다. 그래서 2024, 2025 로 학습하고 2026 으로만 시험했습니다.

Q12. 한국외대만 보면 작년 명단이 모델보다 나았는데요?

네, 검증 학과가 94 개, 지원 수 k 가 16 개뿐이라 한두 곳 차이로 순서가 바뀝니다. 그래서 보조 참고로만 쓰고, 한계 슬라이드에 적었습니다.

Q13. 이 결과로 '사립이라서 학생이 떠난다'고 할 수 있나요?

없습니다. 학과 단위 집계의 상관입니다. 사립, 비수도권 학교의 학생 구성이나 재정 같은, 데이터에 없는 요인이 함께 작용했을 수 있습니다.

Q14. AI 는 어떻게 썼고, 어떻게 검증했나요?

코드 작성과 정리에 썼고, 모든 숫자는 노트북 셀 출력과 대조했습니다. AI 가 틀린 진술(안내문 분량, 국제지역학 분류, 가설 B 설명의 과장 등)은 원문 확인과 재계산으로 바로잡아 AI 활용 로그에 남겼습니다.

감점 막기 체크리스트

☐ [ ] 리허설 시간 9:30 안쪽 (1 분 넘으면 −5 점). 9 분 알림이 울리면 11 장의 네 번째 문장을 건너뛴다

☐ [ ] 가설 A '맞았다', 가설 B '틀렸다'를 소리 내어 말한다

☐ [ ] 예측 성능은 반드시 기준선(작년 명단)과 같이 말한다

□ [ ] 한계 3 종(테스트 1 년, 상관≠인과, 생존 편향)을 말한다

□ [ ] 모든 수치는 슬라이드 하단 출처 줄과 같은지 확인 (출처 없는 수치 −2 점)

□ [ ] 발표하지 않는 팀원도 '예상 질문'을 읽고 답할 수 있다 (교수는 누구에게나 질문)

□ [ ] 발표 전날 23:59 까지 PDF 제출