빅데이터분석 팀 프로젝트 2 제출물

정제 로그

다음 학년도 중도탈락 고위험 학과는 어디인가 | 처리, 건수, 근거, 영향 (노트북 § ③ 정제 출력 기준)

과 목	빅데이터분석
담당교수	박주원
조	14 조
팀 원	정승엽, 박유진, 신효주
자료 저장소	github.com/202103116-stack/university-dropout-risk-analysis
Colab 노트북	Colab(정승엽, 팀 정본) | Colab(박유진)

2026. 11. 12.

14 조

이 파일은 노트북 **§③ 정제** 셀의 출력을 정리한 기록이다. 건수에는 **코드가 계산한 값만** 쓴다.

보고서나 발표에 옮기기 전에 노트북을 '다시 시작 및 모두 실행'해서 같은 숫자가 나오는지 직접 확인한다.

기대값 칸의 숫자는 계획서 기준값이다. 노트북을 다시 실행해 확정해야 한다.

보고서와 발표에서는 표 번호로 출처를 단다. 예: (출처: 정제로그 표 4 / 노트북 §③ 셀 12)

원칙

처리하기 전에 분석 범위(일반 대학 주간 학과)와 분석 표본에 영향이 있는지 먼저 센다. 손대지 않은 것도 이유를 남긴다.

행은 지우지 않는다. **표시(flag)한 뒤 분석 표본에서 제외하고**, 제외 건수와 근거를 공개한다.

y(중도탈락학생비율)에는 평균 대체 같은 보정을 하지 않는다.

결과를 바꾸는 처리는 선택지와 장단점을 팀에 보여주고, 결정을 받은 뒤에 한다. AI 가 정하지 않은 처리를 임의로 하지 않는다.

분류는 데이터 컬럼만 쓴다. 수작업 매핑이나 재분류는 하지 않는다.

표 1. 사전 진단 (정제 전, 데이터는 바꾸지 않음)

구분	기대값 (계획서 기준값)	노트북 값	셀
전체 행 × 열	56,340 × 32	56,340 × 32 ✓	s2-02
공시 2023 / 2024 / 2025 / 2026 행 수 (전체)	14,350 / 13,628 / 13,928 / 14,434	같음 ✓	s2-03
범위(일반 대학 주간) 행 수	50,081 (88.9%), 210 개교	50,081 (88.9%), 210 개교 ✓	s3-16
범위 공시연도별 행 수	12,676 / 12,116 / 12,388 / 12,901	같음 ✓	s3-16
전년→당해 연결 쌍 (전체 기준, 두 해 모두 재적>0, 비율 유효)	29,071	29,071 ✓	s3-06
전년→당해 연결 쌍 (두 해 모두 범위 안)	—	32,006	s3-18
분석 표본 (범위 + 두 해 비율 유효 + 직전연도 재적≥30)	—	23,114 (학습 15,608 / 테스트 7,506)	s3-19

실행 환경: Python 3.13.14, pandas 3.0.6, numpy 2.5.3, 2026-11-11 실행 (s0-01).

표 2. 정제 순서 (노트북 § ③ 실행 순서)

순서	단계	내용	기대값 (assert, 계획서 기준값)	이 순서인 이유
③-0	사전 진단 (품질 6 대 기준, 읽기 전용)	행, 열 수, 연도별 행 수, 이슈별 건수, 표준분류 일관성을 센다	56,340×32. 연도별 14,350 / 13,628 / 13,928 / 14,434	범위 안 영향을 보고 처리 여부를 정하기 위해
③-1	중복	완전 중복을 먼저 보고, 다음으로 키(공시연도, 학교코드, 학과코드) 중복을 본다	0 / 0. 0 이면 '처리 없음'으로 기록	안내문 기준 "완전 중복 제거를 첫 단계로"
③-2	공백, 표기	컬럼명과 문자열 값의 공백을 점검한다(학과명 앞뒤 공백 1 건 확인됨)	strip 후 컬럼 32 개	이후 groupby, 필터, 병합이 깨지지 않게
③-3	타입 확인	숫자 컬럼이 숫자형인지, 변환할 때 새 결측이 생기지 않는지 본다	변환 전후 NaN 증가 0	숫자여야 모순과 결측을 판단할 수 있음
③-4	논리 모순 표시 (삭제 금지)	재적=0, 재적=0 이면서 계>0, 계>재적, 공시 비율과 계÷재적의 불일치, 사유합≠계	2,500 / 1,497 / 172 / 68 / 0 (전체 기준)	결측을 분해하기 전에 원인을 표시
③-5	결측 분해	비율 결측을 '계 결측'과 '재적 0'으로 나누고 연도별 결측률을 비교한다. 보정하지 않고 표본 제외 사유로 기록	6,372 = 5,569 + 803 (전체 기준)	모순 표시를 써서 원인별로 나눔
③-6	**범위 확정 (일반 대학 주간)**	`학교종류=='대학교'`, `주야간구분=='주간'`, `학과특성=='일반과정'`, `학교상태!='폐교'`. 행을 지우지 않고 `in_scope` 표시만 한다. 조건별 제외 건수를 기록	50,081 행. 연도별 12,676 / 12,116 / 12,388 / 12,901	연결과 표본 정의를 범위 안에서만 하기 위해, 패널 연결 **앞**에 둠
③-7	표준분류 N.C.E. 표시	대, 중, 소계열의 분류 불가 행을 세서 공개한다. 재분류하지 않음	0.4% / 4.8% / 9.4% (전체 기준)	B 대상군 경계와 계열 통제 변수의 잡음을 공개
③-8	패널 연결	범위 안에서 (학교코드, 학과코드)로 전년→당해 쌍을 만든다. 신설은 자연 제외. 한국외대 코드 변동과 미연결 건수를 기록	범위 안 t=2024~2026 37,405 행 → 32,006 쌍 (s3-18)	정제된 범위 안 행으로만 연결

순서	단계	내용	기대값 (assert, 계획서 기준값)	이 순서인 이유
③-9	분석 표본 확정	직전연도 재적≥30, 비율 유효 행으로 표본을 확정한다. 행 수는 단계별로 표시. 민감도 표본(재적 10, 50, 전체 표본)도 함께 만든다	단계별 추적표 (표 5)	표본 정의는 마지막에 한 번
③-10	손대지 않는 것과 최종 점검	손대지 않은 이유를 기록하고(표 8), 필터 전후 행 수와 0 행 무음 실패를 확인	assert 통과	숫자 불일치와 무음 실패를 잡기 위해

표 3. 전체에 적용한 처리 vs 분석 표본 안에서만 적용한 처리

전체 표에 적용 (범위, 표본과 무관)

처리	전체에 적용한 이유
컬럼명, 문자열 공백 제거	형식 문제라 표본과 상관없이 해야 코드가 깨지지 않음
숫자 타입 확인, 변환	컬럼 단위 변환
이슈 표시(flag) 컬럼과 `in_scope` 표시 추가	값을 바꾸지 않는 표시라 전체에 붙여, 추적표를 같은 기준으로 셈

분석 표본 안에서만 적용

처리	표본 안에서만 적용한 이유
범위 밖 행(사이버, 산업, 교육대, 야간, 계약학과, 폐교 등) 제외	탈락 메커니즘이 다름. 행은 남기고 민감도 ②에서 다시 사용
재적=0, 비율 결측, 신설 행 제외	값을 지우거나 고치지 않고 표본 정의에서만 뺌. 원본 행은 남아 있어 건수를 공개
직전연도 재적 ≥ 30 (민감도 10, 50)	소규모 학과의 비율 변동을 통제. 기준은 분석 설계에서 사전 고정

> 기준: "값 자체를 바꾸는 보정"은 하지 않는다. "표본에 넣을지 말지"만 정한다. y(비율)는 공시값을 그대로 쓴다.

표 4. 정제 처리 로그 (처리, 건수, 근거, 영향)

건수 표기: `원본 전체 → 범위 안 → 연결 쌍 → 분석 표본` (코드가 계산한 값, 출처: 노트북 s3-20 / `data/processed/cleaning_log.csv`)

#	처리	건수	근거	영향 (채택/수정/기각과 이유)
1	완전 중복, 키 중복 확인	0 / 0	안내문: 완전 중복 제거를 첫 단계로	처리 없음 (제거할 행 없음)
2	컬럼명, 문자열 공백 제거	374 셀 (학과명 1, 표준분류_소계열 '유아교육 ' 373)	같은 값이 공백 때문에 다른 범주로 갈림	값 의미 변화 없음. B 대상군, N.C.E.와는 무관
3	숫자 타입 확인	15 개 컬럼, 새 결측 0	변환 전후 결측 수 동일	처리 없음
4	재적 = 0 표시 → 표본 제외	2,500 → 범위 안 2,261 → 표본 0	비율 분모 0	분석 표본에서 제외(행 유지)
5	재적 = 0 이면서 계 > 0 표시	1,497	분모, 분자 모순	재적 0 행은 모두 y 로 쓰지 않음
5-1	**재적 = 0 인데 비율이 0%로 기록됨** (새로 발견)	1,697 (그중 계 > 0 도 다수)	비율 칸에 값은 있지만 분모가 0 이라 의미 없는 0%	y 로 쓰지 않음(`rate_valid` = 재적>0, 계, 비율 모두 있음). 비율 칸만 보면 놓치는 함정
6	계 > 재적(비율 100% 초과) 표시, 값 수정 안 함	172 (87%가 재적 5 명 이하) → 표본 12	소규모 학과 변동 또는 집계 시점 차이	직전연도 최소 재적 30 명으로 통제, 값은 그대로
7	공시 비율 vs 계÷재적 불일치 표시	0 (0.01%p 초과 기준). 최대 차이 0.005%p	반올림 수준. 계획서 기준값 '68 행'은 이 정의로 재현되지 않음(정의 차이로 추정)	공시값 사용(팀 결정 2026-11-11)
8	비율 결측 분해 → 표본 제외	6,372 = 계 결측 5,569 + 재적 0 803	2023 0.8% / 2024 14.8% / 2025 14.7% / 2026 15.2%	보정 안 함(y 결측 대체 금지). 2024 년부터 결측이 늘어난 것은 공시 방식 변화로 보이며 한계 ③에 기록
9	범위 확정: 일반 대학 주간 학과	56,340 → 50,081 (88.9%)	팀 결정(2026-11-11). 가설 문서 2 절	범위 밖 6,259 행은 민감도 ②에만 사용
10	표준분류 N.C.E.: 재분류 안 함	범위 안 소계열 4,788, 중계열 2,391 / 한국외대 소계열 85, 중계열 35	학교별 신고에 의존(가설 문서 3 절)	'분류 불가' 범주로 둠. 소계열은 B 대상군 정의에만 사용
11	패널 연결 (두 해 모두 범위 안)	t=2024~2026 범위 안 37,405 행 → 32,006 쌍 (미연결 5,399)	신설, 코드 변경 학과는 전년도 행이 없음	생존 편향을 한계로 명시
12	한국외대 학과코드 미연결	61 (2024 6 / 2025 17 / 2026 38)	학부, 전공 개편	B 예측 절 평가에서 제외하고 건수 공개. B 판정은 군 단위 풀링이라 연결 불필요
13	두 해 비율 유효 + 직전연도 재적 ≥ 30	32,006 → 27,316 → 25,867 → 23,114 쌍	사전 고정 설계	민감도: 재적≥10 25,008 / 재적≥50 21,193 / 전체 표본 25,836

표 5. 이슈별 건수 단계별 추적표

출처: 노트북 s3-20 / `data/processed/cleaning_track.csv`

이슈	① 원본 전체	② 중복 확인 후	③ 범위 안 (일반 대학 주간)	④ 연결 쌍 (당해 기준)	⑤ 분석 표본 (재적≥30)	민감도 (재적≥10)	민감도 (재적≥50)
(참고) 행 수	56,340	56,340	50,081	32,006	23,114	25,008	21,193
재적 = 0	2,500	2,500	2,261	276	0	0	0
재적 = 0 이면서 계 > 0	1,497	1,497	1,359	221	0	0	0
재적 = 0 인데 비율 기록됨(0%)	1,697	1,697	1,516	95	0	0	0
계 > 재적 (재적 > 0)	172	172	158	87	12	37	5
재계산 불일치 (> 0.01%p)	0	0	0	0	0	0	0
사유합 ≠ 계	0	0	0	0	0	0	0
비율 결측	6,372	6,372	5,585	4,595	0	0	0
ㄴ 계 결측	5,569	5,569	4,840	4,414	0	0	0
ㄴ 재적 0 (계 있음)	803	803	745	181	0	0	0
폐교	493	493	0	0	0	0	0
신설	263	263	256	45	13	15	11
소계열 N.C.E.	5,279	5,279	4,788	2,750	1,838	2,081	1,627
중계열 N.C.E	2,677	2,677	2,391	1,261	839	967	733

④, ⑤의 이슈 건수는 '당해(t)' 행 기준이다. 분석 표본에 남은 '계 > 재적' 12 건은 당해 값이 100%를 넘는 경우로, 값을 고치지 않고 그대로 둔다(직전연도 재적≥30 조건은 전년도 기준).

신설 학교 학과 13 쌍은 v2 범위 조건(폐교만 제외)에 따라 표본에 남는다.

표 6. 비교: 판단에 따라 결과가 바뀌는 처리 (팀 결정 2026-11-11)

처리	선택지 A	선택지 B	결과 차이	팀 결정(날짜)	되돌리는 스위치
공시 비율 vs 계÷재적 재계산	공시값 사용	계÷재적 재계산값 사용	사전 확인 결과 최대 차이 0.005%p(소수 둘째 자리 반올림 수준), 0.01%p 를 넘는 행은 0. 노트북 s3-04 에서 재측정	**공시값 사용 (2026-11-11)**	`RATE_SOURCE`
최소 재적 기준	30	10 / 50	표본 23,114 vs 25,008 / 21,193 쌍. 결과 차이는 ④ 민감도 표	사전 고정: 30	`MIN_ENROLL`
분석 범위	일반 대학 주간	전체 표본	표본 23,114 vs 25,836 쌍. 결과 차이는 ④ 민감도 표	사전 고정: 일반 대학 주간 (2026-11-11)	`SCOPE`
B 대상군	어문 2 개 소계열	+ 국제지역학 소계열	결과 차이는 ④ 민감도 표	사전 고정: 어문 2 개	`B_SUBFIELDS`

표 7. 정제 전/후 집계

```
정제 전 전체 행 수:                56,340   (s2-02)
범위 안 행 수 (일반 대학 주간):    50,081   (s3-16)
전년→당해 연결 쌍 (범위 안):       32,006   (s3-18)
분석 표본 (학습 t=2024, 2025):      15,608   (s3-19)
분석 표본 (테스트 t=2026):          7,506   (s3-19)
```

필터 결과 행 수가 0 이면 코드보다 조건을 먼저 의심한다(노트북에 assert 를 둔다).

표 8. 손대지 않기로 한 것 (이유 포함)

□ **비율 100% 초과 행**: 값을 고치지 않고 표시만 한다. 최소 재적 기준으로 통제하고, 민감도로 영향을 확인한다.

□ **사유 컬럼**: 사유합 = 계 정합성이 확인되면 보정하지 않는다.

□ **y(중도탈락학생비율)**: 평균 대체 등 어떤 보정도 하지 않는다.

□ **표준분류 대, 중, 소계열**

○ 학과를 재분류하지 않고, 수작업 매핑표도 만들지 않는다.

○ 애매한 학과는 데이터 값을 그대로 쓴다(예: 글로벌스포츠산업학부 = 경영, 경제 / 경영학).

○ N.C.E.는 하나의 '분류 불가' 범주로 둔다.

○ 이유: 팀이 분류를 바꾸면 결과를 보고 그룹을 고르는 위험이 생긴다. 분류가 갈리는 문제는 한계로 공개한다.

□ **범위 밖 행**: 지우지 않고 `in_scope=False`로 남긴다. 민감도 ②에서 다시 쓴다.

□ **한국외대 학과코드 변동**: 학과명으로 억지로 이어 붙이지 않는다. 대신 B 는 군 단위 풀링으로 비교한다.

□ **학부, 전공 이중 계상 가능성(한국외대)**: 값은 바꾸지 않는다. 재적 합계와 학교 공시 총재적을 대조해 확인 결과만 기록한다. `[확인 필요]`

□ **재적 0 인데 비율 0%로 기록된 1,697 행**: 0%를 결측으로 바꾸지 않는다. 대신 `rate_valid`(재적>0)로 y 에서 빼고, 원본 값은 그대로 둔다.

□ **신설 학교의 학과**: v2 범위 조건은 폐교만 제외한다. 전년도 행이 있는 신설 학교 학과(분석 표본 13 쌍)는 그대로 남긴다.

□ **개편 전 잔류, 신설 초기로 추정되는 작은 단위**(한국외대 19 개, 연평균 재적 30 명 미만): 행과 값은 그대로 두고, 부록 R1 의 비율 순위에서만 '비율 해석 불가'로 표시해 뺀다(노트북 sE-02, 원판정 sE-01 은 그대로). 근거: 재적 감소, 학과코드 소멸, 탈락 사유 대부분 미복학. 개편 이력은 `[확인 필요]`.

□ **기준연도 ≠ 공시연도 − 1 인 행**(연도별 101~172 행): 공시연도를 시간 축으로 쓴다. 기준연도는 바꾸지 않는다(s2-03).