빅데이터분석 팀 프로젝트 2 제출물

# 정제 로그

다음 학년도 중도탈락 고위험 학과는 어디인가 | 처리, 건수, 근거, 영향 (노트북 § ③ 정제 출력 기준)

| | |
|---|---|
| **과 목** | 빅데이터분석 |
| **담당교수** | 박주원 |
| **조** | 14 조 |
| **팀 원** | 정승엽, 박유진, 신효주 |
| **자료 저장소** | github.com/202103116-stack/university-dropout-risk-analysis |
| **Colab 노트북** | Colab(정승엽, 팀 정본) \| Colab(박유진) |

2026. 11. 12.

**14 조**

이 파일은 노트북 **§③ 정제** 셀의 출력을 정리한 기록이다. 건수에는 **코드가 계산한 값만** 쓴다.

보고서나 발표에 옮기기 전에 노트북을 '다시 시작 및 모두 실행'해서 같은 숫자가 나오는지 직접 확인한다.

기대값 칸의 숫자는 계획서 기준값이다. 노트북을 다시 실행해 확정해야 한다.

보고서와 발표에서는 표 번호로 출처를 단다. 예: (출처: 정제로그 표 4 / 노트북 §③ 셀 12)

**원칙**

처리하기 전에 분석 범위(일반 대학 주간 학과)와 분석 표본에 영향이 있는지 먼저 센다. 손대지 않은 것도 이유를 남긴다.

행은 지우지 않는다. **표시(flag)한 뒤 분석 표본에서 제외하고**, 제외 건수와 근거를 공개한다.

y(중도탈락학생비율)에는 평균 대체 같은 보정을 하지 않는다.

결과를 바꾸는 처리는 선택지와 장단점을 팀에 보여주고, 결정을 받은 뒤에 한다. AI 가 정하지 않은 처리를 임의로 하지 않는다.

분류는 데이터 컬럼만 쓴다. 수작업 매핑이나 재분류는 하지 않는다.

# 표 1. 사전 진단 (정제 전, 데이터는 바꾸지 않음)

| 구분 | 기대값 (계획서 기준값) | 노트북 값 | 셀 |
|---|---|---|---|
| 전체 행 × 열 | 56,340 × 32 | 56,340 × 32 ✓ | s2-02 |
| 공시 2023 / 2024 / 2025 / 2026 행 수 (전체) | 14,350 / 13,628 / 13,928 / 14,434 | 같음 ✓ | s2-03 |
| 범위(일반 대학 주간) 행 수 | 50,081 (88.9%), 210 개교 | 50,081 (88.9%), 210 개교 ✓ | s3-16 |
| 범위 공시연도별 행 수 | 12,676 / 12,116 / 12,388 / 12,901 | 같음 ✓ | s3-16 |
| 전년→당해 연결 쌍 (전체 기준, 두 해 모두 재적>0, 비율 유효) | 29,071 | 29,071 ✓ | s3-06 |
| 전년→당해 연결 쌍 (두 해 모두 범위 안) | — | 32,006 | s3-18 |
| 분석 표본 (범위 + 두 해 비율 유효 + 직전연도 재적≥30) | — | 23,114 (학습 15,608 / 테스트 7,506) | s3-19 |

실행 환경: Python 3.13.14, pandas 3.0.6, numpy 2.5.3, 2026-11-11 실행 (s0-01).

# 표 2. 정제 순서 (노트북 § ③ 실행 순서)

| 순서 | 단계 | 내용 | 기대값 (assert, 계획서 기준값) | 이 순서인 이유 |
|---|---|---|---|---|
| ③-0 | 사전 진단 (품질 6 대 기준, 읽기 전용) | 행, 열 수, 연도별 행 수, 이슈별 건수, 표준분류 일관성을 센다 | 56,340×32. 연도별 14,350 / 13,628 / 13,928 / 14,434 | 범위 안 영향을 보고 처리 여부를 정하기 위해 |
| ③-1 | 중복 | 완전 중복을 먼저 보고, 다음으로 키(공시연도, 학교코드, 학과코드) 중복을 본다 | 0 / 0. 0 이면 '처리 없음'으로 기록 | 안내문 기준 "완전 중복 제거를 첫 단계로" |
| ③-2 | 공백, 표기 | 컬럼명과 문자열 값의 공백을 점검한다(학과명 앞뒤 공백 1 건 확인됨) | strip 후 컬럼 32 개 | 이후 groupby, 필터, 병합이 깨지지 않게 |
| ③-3 | 타입 확인 | 숫자 컬럼이 숫자형인지, 변환할 때 새 결측이 생기지 않는지 본다 | 변환 전후 NaN 증가 0 | 숫자여야 모순과 결측을 판단할 수 있음 |
| ③-4 | 논리 모순 표시 (삭제 금지) | 재적=0, 재적=0 이면서 계>0, 계>재적, 공시 비율과 계÷재적의 불일치, 사유합≠계 | 2,500 / 1,497 / 172 / 68 / 0 (전체 기준) | 결측을 분해하기 전에 원인을 표시 |
| ③-5 | 결측 분해 | 비율 결측을 '계 결측'과 '재적 0'으로 나누고 연도별 결측률을 비교한다. 보정하지 않고 표본 제외 사유로 기록 | 6,372 = 5,569 + 803 (전체 기준) | 모순 표시를 써서 원인별로 나눔 |
| **③-6** | **범위 확정 (일반 대학 주간)** | `학교종류=='대학교'`, `주야간구분=='주간'`, `학과특성=='일반과정'`, `학교상태!='폐교'`. 행을 지우지 않고 `in_scope` 표시만 한다. 조건별 제외 건수를 기록 | 50,081 행. 연도별 12,676 / 12,116 / 12,388 / 12,901 | 연결과 표본 정의를 범위 안에서만 하기 위해, 패널 연결 **앞**에 둠 |
| ③-7 | 표준분류 N.C.E. 표시 | 대, 중, 소계열의 분류 불가 행을 세서 공개한다. 재분류하지 않음 | 0.4% / 4.8% / 9.4% (전체 기준) | B 대상군 경계와 계열 통제 변수의 잡음을 공개 |
| ③-8 | 패널 연결 | 범위 안에서 (학교코드, 학과코드)로 전년→당해 쌍을 만든다. 신설은 자연 제외. 한국외대 코드 변동과 미연결 건수를 기록 | (노트북 실행 후 기입). 결합 전후 행 수 기록 | 정제된 범위 안 행으로만 연결 |

| 순서 | 단계 | 내용 | 기대값 (assert, 계획서 기준값) | 이 순서인 이유 |
|---|---|---|---|---|
| ③-9 | 분석 표본 확정 | 직전연도 재적≥30, 비율 유효 행으로 표본을 확정한다. 행 수는 단계별로 표시. 민감도 표본(재적 10, 50, 전체 표본)도 함께 만든다 | 단계별 추적표 (표 5) | 표본 정의는 마지막에 한 번 |
| ③-10 | 손대지 않는 것과 최종 점검 | 손대지 않은 이유를 기록하고(표 8), 필터 전후 행 수와 0 행 무음 실패를 확인 | assert 통과 | 숫자 불일치와 무음 실패를 잡기 위해 |

# 표 3. 전체에 적용한 처리 vs 분석 표본 안에서만 적용한 처리

### 전체 표에 적용 (범위, 표본과 무관)

| 처리 | 전체에 적용한 이유 |
|---|---|
| 컬럼명, 문자열 공백 제거 | 형식 문제라 표본과 상관없이 해야 코드가 깨지지 않음 |
| 숫자 타입 확인, 변환 | 컬럼 단위 변환 |
| 이슈 표시(flag) 컬럼과 `in_scope` 표시 추가 | 값을 바꾸지 않는 표시라 전체에 붙여, 추적표를 같은 기준으로 셈 |

### 분석 표본 안에서만 적용

| 처리 | 표본 안에서만 적용한 이유 |
|---|---|
| 범위 밖 행(사이버, 산업, 교육대, 야간, 계약학과, 폐교 등) 제외 | 탈락 메커니즘이 다름. 행은 남기고 민감도 ②에서 다시 사용 |
| 재적=0, 비율 결측, 신설 행 제외 | 값을 지우거나 고치지 않고 표본 정의에서만 뺌. 원본 행은 남아 있어 건수를 공개 |
| 직전연도 재적 ≥ 30 (민감도 10, 50) | 소규모 학과의 비율 변동을 통제. 기준은 분석 설계에서 사전 고정 |

기준: "값 자체를 바꾸는 보정"은 하지 않는다. "표본에 넣을지 말지"만 정한다. y(비율)는 공시값을 그대로 쓴다.

# 표 4. 정제 처리 로그 (처리, 건수, 근거, 영향)

건수 표기: `원본 전체 → 범위 안 → 연결 쌍 → 분석 표본` (코드가 계산한 값, 출처: 노트북 s3-20 / `data/processed/cleaning_log.csv`)

| # | 처리 | 건수 | 근거 | 영향 (채택/수정/기각과 이유) |
|---|---|---|---|---|
| 1 | 완전 중복, 키 중복 확인 | 0 / 0 | 안내문: 완전 중복 제거를 첫 단계로 | 처리 없음 (제거할 행 없음) |
| 2 | 컬럼명, 문자열 공백 제거 | 374 셀 (학과명 1, 표준분류_소계열 '유아교육 ' 373) | 같은 값이 공백 때문에 다른 범주로 갈림 | 값 의미 변화 없음. B 대상군, N.C.E.와는 무관 |
| 3 | 숫자 타입 확인 | 15 개 컬럼, 새 결측 0 | 변환 전후 결측 수 동일 | 처리 없음 |
| 4 | 재적 = 0 표시 → 표본 제외 | 2,500 → 범위 안 2,261 → 표본 0 | 비율 분모 0 | 분석 표본에서 제외(행 유지) |
| 5 | 재적 = 0 이면서 계 > 0 표시 | 1,497 | 분모, 분자 모순 | 재적 0 행은 모두 y 로 쓰지 않음 |
| 5-1 | **재적 = 0 인데 비율이 0%로 기록됨** (새로 발견) | 1,697 (그중 계 > 0 도 다수) | 비율 칸에 값은 있지만 분모가 0 이라 의미 없는 0% | y 로 쓰지 않음(`rate_valid` = 재적>0, 계, 비율 모두 있음). 비율 칸만 보면 놓치는 함정 |
| 6 | 계 > 재적(비율 100% 초과) 표시, 값 수정 안 함 | 172 (87%가 재적 5 명 이하) → 표본 12 | 소규모 학과 변동 또는 집계 시점 차이 | 직전연도 최소 재적 30 명으로 통제, 값은 그대로 |
| 7 | 공시 비율 vs 계÷재적 불일치 표시 | 0 (0.01%p 초과 기준). 최대 차이 0.005%p | 반올림 수준. 계획서 기준값 '68 행'은 이 정의로 재현되지 않음(정의 차이로 추정) | 공시값 사용(팀 결정 2026-11-11) |
| 8 | 비율 결측 분해 → 표본 제외 | 6,372 = 계 결측 5,569 + 재적 0 803 | 2023 0.8% / 2024 14.8% / 2025 14.7% / 2026 15.2% | 보정 안 함(y 결측 대체 금지). 2024 년부터 결측이 늘어난 것은 공시 방식 변화로 보이며 한계 ③에 기록 |
| 9 | 범위 확정: 일반 대학 주간 학과 | 56,340 → 50,081 (88.9%) | 팀 결정(2026-11-11). 가설 문서 2 절 | 범위 밖 6,259 행은 민감도 ②에만 사용 |
| 10 | 표준분류 N.C.E.: 재분류 안 함 | 범위 안 소계열 4,788, 중계열 2,391 / 한국외대 소계열 85, 중계열 35 | 학교별 신고에 의존(가설 문서 3 절) | '분류 불가' 범주로 둠. 소계열은 B 대상군 정의에만 사용 |
| 11 | 패널 연결 (두 해 모두 범위 안) | t=2024~2026 범위 안 37,405 행 → 32,006 쌍 (미연결 5,399) | 신설, 코드 변경 학과는 전년도 행이 없음 | 생존 편향을 한계로 명시 |
| 12 | 한국외대 학과코드 미연결 | 61 (2024 6 / 2025 17 / 2026 38) | 학부, 전공 개편 | B 예측 절 평가에서 제외하고 건수 공개. B 판정은 군 단위 풀링이라 연결 불필요 |
| 13 | 두 해 비율 유효 + 직전연도 재적 ≥ 30 | 32,006 → 27,316 → 25,867 → 23,114 쌍 | 사전 고정 설계 | 민감도: 재적≥10 25,008 / 재적≥50 21,193 / 전체 표본 25,836 |

# 표 5. 이슈별 건수 단계별 추적표

출처: 노트북 s3-20 / `data/processed/cleaning_track.csv`

| 이슈 | ① 원본 전체 | ② 중복 확인 후 | ③ 범위 안 (일반 대학 주간) | ④ 연결 쌍 (당해 기준) | ⑤ 분석 표본 (재적≥30) | 민감도 (재적≥10) | 민감도 (재적≥50) |
|---|---|---|---|---|---|---|---|
| (참고) 행 수 | 56,340 | 56,340 | 50,081 | 32,006 | 23,114 | 25,008 | 21,193 |
| 재적 = 0 | 2,500 | 2,500 | 2,261 | 276 | 0 | 0 | 0 |
| 재적 = 0 이면서 계 > 0 | 1,497 | 1,497 | 1,359 | 221 | 0 | 0 | 0 |
| 재적 = 0 인데 비율 기록됨(0%) | 1,697 | 1,697 | 1,516 | 95 | 0 | 0 | 0 |
| 계 > 재적 (재적 > 0) | 172 | 172 | 158 | 87 | 12 | 37 | 5 |
| 재계산 불일치 (> 0.01%p) | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 사유합 ≠ 계 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 비율 결측 | 6,372 | 6,372 | 5,585 | 4,595 | 0 | 0 | 0 |
| ㄴ 계 결측 | 5,569 | 5,569 | 4,840 | 4,414 | 0 | 0 | 0 |
| ㄴ 재적 0 (계 있음) | 803 | 803 | 745 | 181 | 0 | 0 | 0 |
| 폐교 | 493 | 493 | 0 | 0 | 0 | 0 | 0 |
| 신설 | 263 | 263 | 256 | 45 | 13 | 15 | 11 |
| 소계열 N.C.E. | 5,279 | 5,279 | 4,788 | 2,750 | 1,838 | 2,081 | 1,627 |
| 중계열 N.C.E | 2,677 | 2,677 | 2,391 | 1,261 | 839 | 967 | 733 |

④, ⑤의 이슈 건수는 '당해(t)' 행 기준이다. 분석 표본에 남은 '계 > 재적' 12 건은 당해 값이 100%를 넘는 경우로, 값을 고치지 않고 그대로 둔다(직전연도 재적≥30 조건은 전년도 기준).

신설 학교 학과 13 쌍은 v2 범위 조건(폐교만 제외)에 따라 표본에 남는다.

# 표 6. 비교: 판단에 따라 결과가 바뀌는 처리 (팀 결정 후 기입)

| 처리 | 선택지 A | 선택지 B | 결과 차이 | 팀 결정(날짜) | 되돌리는 스위치 |
|---|---|---|---|---|---|
| 공시 비율 vs 계÷재적 재계산 | 공시값 사용 | 계÷재적 재계산값 사용 | 사전 확인 결과 최대 차이 0.005%p(소수 둘째 자리 반올림 수준), 0.01%p 를 넘는 행은 0. 노트북 s3-04 에서 재측정 | **공시값 사용 (2026-11-11)** | `RATE_SOURCE` |
| 최소 재적 기준 | 30 | 10 / 50 | 표본 23,114 vs 25,008 / 21,193 쌍. 결과 차이는 ④ 민감도 표 | 사전 고정: 30 | `MIN_ENROLL` |
| 분석 범위 | 일반 대학 주간 | 전체 표본 | 표본 23,114 vs 25,836 쌍. 결과 차이는 ④ 민감도 표 | 사전 고정: 일반 대학 주간 (2026-11-11) | `SCOPE` |
| B 대상군 | 어문 2 개 소계열 | + 국제지역학 소계열 | 결과 차이는 ④ 민감도 표 | 사전 고정: 어문 2 개 | `B_SUBFIELDS` |

# 표 7. 정제 전/후 집계

```
정제 전 전체 행 수:                56,340   (s2-02)
범위 안 행 수 (일반 대학 주간):    50,081   (s3-16)
전년→당해 연결 쌍 (범위 안):       32,006   (s3-18)
분석 표본 (학습 t=2024, 2025):      15,608   (s3-19)
분석 표본 (테스트 t=2026):          7,506   (s3-19)
```

> 필터 결과 행 수가 0 이면 코드보다 조건을 먼저 의심한다(노트북에 assert 를 둔다).

# 표 8. 손대지 않기로 한 것 (이유 포함)

□ **비율 100% 초과 행**: 값을 고치지 않고 표시만 한다. 최소 재적 기준으로 통제하고, 민감도로 영향을 확인한다.

□ **사유 컬럼**: 사유합 = 계 정합성이 확인되면 보정하지 않는다.

□ **y(중도탈락학생비율)**: 평균 대체 등 어떤 보정도 하지 않는다.

□ **표준분류 대, 중, 소계열**

○ 학과를 재분류하지 않고, 수작업 매핑표도 만들지 않는다.

○ 애매한 학과는 데이터 값을 그대로 쓴다(예: 글로벌스포츠산업학부 = 경영, 경제 / 경영학).

○ N.C.E.는 하나의 '분류 불가' 범주로 둔다.

○ 이유: 팀이 분류를 바꾸면 결과를 보고 그룹을 고르는 위험이 생긴다. 분류가 갈리는 문제는 한계로 공개한다.

□ **범위 밖 행**: 지우지 않고 `in_scope=False`로 남긴다. 민감도 ②에서 다시 쓴다.

□ **한국외대 학과코드 변동**: 학과명으로 억지로 이어 붙이지 않는다. 대신 B 는 군 단위 풀링으로 비교한다.

□ **학부, 전공 이중 계상 가능성(한국외대)**: 값은 바꾸지 않는다. 재적 합계와 학교 공시 총재적을 대조해 확인 결과만 기록한다. `[확인 필요]`

□ **재적 0 인데 비율 0%로 기록된 1,697 행**: 0%를 결측으로 바꾸지 않는다. 대신 `rate_valid`(재적>0)로 y 에서 빼고, 원본 값은 그대로 둔다.

□ **신설 학교의 학과**: v2 범위 조건은 폐교만 제외한다. 전년도 행이 있는 신설 학교 학과(분석 표본 13 쌍)는 그대로 남긴다.

□ **개편 전 잔류, 신설 초기로 추정되는 작은 단위**(한국외대 19 개, 연평균 재적 30 명 미만): 행과 값은 그대로 두고, 부록 R1 의 비율 순위에서만 '비율 해석 불가'로 표시해 뺀다(노트북 sE-02, 원판정 sE-01 은 그대로). 근거: 재적 감소, 학과코드 소멸, 탈락 사유 대부분 미복학. 개편 이력은 `[확인 필요]`.

□ **기준연도 ≠ 공시연도 − 1 인 행**(연도별 101~172 행): 공시연도를 시간 축으로 쓴다. 기준연도는 바꾸지 않는다(s2-03).