빅데이터분석 팀 프로젝트 2 제출물 합본

# 제출물 합본

다음 학년도 중도탈락 고위험 학과는 어디인가 | 정제 로그, AI 활용 로그, 기여도표

| | |
|---|---|
| **과 목** | 빅데이터분석 |
| **담당교수** | 박주원 |
| **조** | 14 조 |
| **팀 원** | 정승엽, 박유진, 신효주 |
| **자료 저장소** | github.com/202103116-stack/university-dropout-risk-analysis |
| **Colab 노트북** | Colab(정승엽, 팀 정본) \| Colab(박유진) |

2026. 11. 12.

**14 조**

# 목 차

정제 로그 ..... 1
표 1. 사전 진단 (정제 전, 데이터는 바꾸지 않음) ..... 1
표 2. 정제 순서 (노트북 §③ 실행 순서) ..... 2
표 3. 전체에 적용한 처리 vs 분석 표본 안에서만 적용한 처리 ..... 3
표 4. 정제 처리 로그 (처리, 건수, 근거, 영향) ..... 3
표 5. 이슈별 건수 단계별 추적표 ..... 5
표 6. 비교: 판단에 따라 결과가 바뀌는 처리 (팀 결정 2026-11-11) ..... 5
표 7. 정제 전/후 집계 ..... 6
표 8. 손대지 않기로 한 것 (이유 포함) ..... 6
AI 활용 로그 ..... 8
AI 활용 원칙 ..... 8
단계별 기록 (내가 지시한 것 / AI 가 제안한 것 / 채택, 수정, 기각한 것) ..... 8
AI 진술을 바로잡은 사례 ..... 9
기여도표 ..... 10
기여 비율 ..... 10

# 정제 로그

이 파일은 노트북 **§③ 정제** 셀의 출력을 정리한 기록이다. 건수에는 **코드가 계산한 값만** 쓴다.

보고서나 발표에 옮기기 전에 노트북을 '다시 시작 및 모두 실행'해서 같은 숫자가 나오는지 직접 확인한다.

기대값 칸의 숫자는 계획서 기준값이다. 노트북을 다시 실행해 확정해야 한다.

보고서와 발표에서는 표 번호로 출처를 단다. 예: (출처: 정제로그 표 4 / 노트북 §③ 셀 12)

**원칙**

처리하기 전에 분석 범위(일반 대학 주간 학과)와 분석 표본에 영향이 있는지 먼저 센다. 손대지 않은 것도 이유를 남긴다.

행은 지우지 않는다. **표시(flag)한 뒤 분석 표본에서 제외하고**, 제외 건수와 근거를 공개한다.

y(중도탈락학생비율)에는 평균 대체 같은 보정을 하지 않는다.

결과를 바꾸는 처리는 선택지와 장단점을 팀에 보여주고, 결정을 받은 뒤에 한다. AI 가 정하지 않은 처리를 임의로 하지 않는다.

분류는 데이터 컬럼만 쓴다. 수작업 매핑이나 재분류는 하지 않는다.

## 표 1. 사전 진단 (정제 전, 데이터는 바꾸지 않음)

| 구분 | 기대값 (계획서 기준값) | 노트북 값 | 셀 |
|---|---|---|---|
| 전체 행 × 열 | 56,340 × 32 | 56,340 × 32 ✓ | s2-02 |
| 공시 2023 / 2024 / 2025 / 2026 행 수 (전체) | 14,350 / 13,628 / 13,928 / 14,434 | 같음 ✓ | s2-03 |
| 범위(일반 대학 주간) 행 수 | 50,081 (88.9%), 210 개교 | 50,081 (88.9%), 210 개교 ✓ | s3-16 |
| 범위 공시연도별 행 수 | 12,676 / 12,116 / 12,388 / 12,901 | 같음 ✓ | s3-16 |
| 전년→당해 연결 쌍 (전체 기준, 두 해 모두 재적>0, 비율 유효) | 29,071 | 29,071 ✓ | s3-06 |
| 전년→당해 연결 쌍 (두 해 모두 범위 안) | — | 32,006 | s3-18 |
| 분석 표본 (범위 + 두 해 비율 유효 + 직전연도 재적≥30) | — | 23,114 (학습 15,608 / 테스트 7,506) | s3-19 |

실행 환경: Python 3.13.14, pandas 3.0.6, numpy 2.5.3, 2026-11-11 실행 (s0-01).

## 표 2. 정제 순서 (노트북 § ③ 실행 순서)

| 순서 | 단계 | 내용 | 기대값 (assert, 계획서 기준값) | 이 순서인 이유 |
|---|---|---|---|---|
| ③-0 | 사전 진단 (품질 6 대 기준, 읽기 전용) | 행, 열 수, 연도별 행 수, 이슈별 건수, 표준분류 일관성을 센다 | 56,340×32. 연도별 14,350 / 13,628 / 13,928 / 14,434 | 범위 안 영향을 보고 처리 여부를 정하기 위해 |
| ③-1 | 중복 | 완전 중복을 먼저 보고, 다음으로 키(공시연도, 학교코드, 학과코드) 중복을 본다 | 0 / 0. 0 이면 '처리 없음'으로 기록 | 안내문 기준 "완전 중복 제거를 첫 단계로" |
| ③-2 | 공백, 표기 | 컬럼명과 문자열 값의 공백을 점검한다(학과명 앞뒤 공백 1 건 확인됨) | strip 후 컬럼 32 개 | 이후 groupby, 필터, 병합이 깨지지 않게 |
| ③-3 | 타입 확인 | 숫자 컬럼이 숫자형인지, 변환할 때 새 결측이 생기지 않는지 본다 | 변환 전후 NaN 증가 0 | 숫자여야 모순과 결측을 판단할 수 있음 |
| ③-4 | 논리 모순 표시 (삭제 금지) | 재적=0, 재적=0 이면서 계>0, 계>재적, 공시 비율과 계÷재적의 불일치, 사유합≠계 | 2,500 / 1,497 / 172 / 68 / 0 (전체 기준) | 결측을 분해하기 전에 원인을 표시 |
| ③-5 | 결측 분해 | 비율 결측을 '계 결측'과 '재적 0'으로 나누고 연도별 결측률을 비교한다. 보정하지 않고 표본 제외 사유로 기록 | 6,372 = 5,569 + 803 (전체 기준) | 모순 표시를 써서 원인별로 나눔 |
| **③-6** | **범위 확정 (일반 대학 주간)** | `학교종류=='대학교'`, `주야간구분=='주간'`, `학과특성=='일반과정'`, `학교상태!='폐교'`. 행을 지우지 않고 `in_scope` 표시만 한다. 조건별 제외 건수를 기록 | 50,081 행. 연도별 12,676 / 12,116 / 12,388 / 12,901 | 연결과 표본 정의를 범위 안에서만 하기 위해, 패널 연결 **앞**에 둠 |
| ③-7 | 표준분류 N.C.E. 표시 | 대, 중, 소계열의 분류 불가 행을 세서 공개한다. 재분류하지 않음 | 0.4% / 4.8% / 9.4% (전체 기준) | B 대상군 경계와 계열 통제 변수의 잡음을 공개 |
| ③-8 | 패널 연결 | 범위 안에서 (학교코드, 학과코드)로 전년→당해 쌍을 만든다. 신설은 자연 제외. 한국외대 코드 변동과 미연결 건수를 기록 | 범위 안 t=2024~2026 37,405 행 → 32,006 쌍 (s3-18) | 정제된 범위 안 행으로만 연결 |

| 순서 | 단계 | 내용 | 기대값 (assert, 계획서 기준값) | 이 순서인 이유 |
|---|---|---|---|---|
| ③-9 | 분석 표본 확정 | 직전연도 재적≥30, 비율 유효 행으로 표본을 확정한다. 행 수는 단계별로 표시. 민감도 표본(재적 10, 50, 전체 표본)도 함께 만든다 | 단계별 추적표 (표 5) | 표본 정의는 마지막에 한 번 |
| ③-10 | 손대지 않는 것과 최종 점검 | 손대지 않은 이유를 기록하고(표 8), 필터 전후 행 수와 0 행 무음 실패를 확인 | assert 통과 | 숫자 불일치와 무음 실패를 잡기 위해 |

## 표 3. 전체에 적용한 처리 vs 분석 표본 안에서만 적용한 처리

### 전체 표에 적용 (범위, 표본과 무관)

| 처리 | 전체에 적용한 이유 |
|---|---|
| 컬럼명, 문자열 공백 제거 | 형식 문제라 표본과 상관없이 해야 코드가 깨지지 않음 |
| 숫자 타입 확인, 변환 | 컬럼 단위 변환 |
| 이슈 표시(flag) 컬럼과 `in_scope` 표시 추가 | 값을 바꾸지 않는 표시라 전체에 붙여, 추적표를 같은 기준으로 셈 |

### 분석 표본 안에서만 적용

| 처리 | 표본 안에서만 적용한 이유 |
|---|---|
| 범위 밖 행(사이버, 산업, 교육대, 야간, 계약학과, 폐교 등) 제외 | 탈락 메커니즘이 다름. 행은 남기고 민감도 ②에서 다시 사용 |
| 재적=0, 비율 결측, 신설 행 제외 | 값을 지우거나 고치지 않고 표본 정의에서만 뺌. 원본 행은 남아 있어 건수를 공개 |
| 직전연도 재적 ≥ 30 (민감도 10, 50) | 소규모 학과의 비율 변동을 통제. 기준은 분석 설계에서 사전 고정 |

> 기준: "값 자체를 바꾸는 보정"은 하지 않는다. "표본에 넣을지 말지"만 정한다. y(비율)는 공시값을 그대로 쓴다.

## 표 4. 정제 처리 로그 (처리, 건수, 근거, 영향)

건수 표기: `원본 전체 → 범위 안 → 연결 쌍 → 분석 표본` (코드가 계산한 값, 출처: 노트북 s3-20 / `data/processed/cleaning_log.csv`)

| # | 처리 | 건수 | 근거 | 영향 (채택/수정/기각과 이유) |
|---|---|---|---|---|
| 1 | 완전 중복, 키 중복 확인 | 0 / 0 | 안내문: 완전 중복 제거를 첫 단계로 | 처리 없음 (제거할 행 없음) |
| 2 | 컬럼명, 문자열 공백 제거 | 374 셀 (학과명 1, 표준분류_소계열 '유아교육 ' 373) | 같은 값이 공백 때문에 다른 범주로 갈림 | 값 의미 변화 없음. B 대상군, N.C.E.와는 무관 |
| 3 | 숫자 타입 확인 | 15 개 컬럼, 새 결측 0 | 변환 전후 결측 수 동일 | 처리 없음 |
| 4 | 재적 = 0 표시 → 표본 제외 | 2,500 → 범위 안 2,261 → 표본 0 | 비율 분모 0 | 분석 표본에서 제외(행 유지) |
| 5 | 재적 = 0 이면서 계 > 0 표시 | 1,497 | 분모, 분자 모순 | 재적 0 행은 모두 y 로 쓰지 않음 |
| 5-1 | **재적 = 0 인데 비율이 0%로 기록됨** (새로 발견) | 1,697 (그중 계 > 0 도 다수) | 비율 칸에 값은 있지만 분모가 0 이라 의미 없는 0% | y 로 쓰지 않음(`rate_valid` = 재적>0, 계, 비율 모두 있음). 비율 칸만 보면 놓치는 함정 |
| 6 | 계 > 재적(비율 100% 초과) 표시, 값 수정 안 함 | 172 (87%가 재적 5 명 이하) → 표본 12 | 소규모 학과 변동 또는 집계 시점 차이 | 직전연도 최소 재적 30 명으로 통제, 값은 그대로 |
| 7 | 공시 비율 vs 계÷재적 불일치 표시 | 0 (0.01%p 초과 기준). 최대 차이 0.005%p | 반올림 수준. 계획서 기준값 '68 행'은 이 정의로 재현되지 않음(정의 차이로 추정) | 공시값 사용(팀 결정 2026-11-11) |
| 8 | 비율 결측 분해 → 표본 제외 | 6,372 = 계 결측 5,569 + 재적 0 803 | 2023 0.8% / 2024 14.8% / 2025 14.7% / 2026 15.2% | 보정 안 함(y 결측 대체 금지). 2024 년부터 결측이 늘어난 것은 공시 방식 변화로 보이며 한계 ③에 기록 |
| 9 | 범위 확정: 일반 대학 주간 학과 | 56,340 → 50,081 (88.9%) | 팀 결정(2026-11-11). 가설 문서 2 절 | 범위 밖 6,259 행은 민감도 ②에만 사용 |
| 10 | 표준분류 N.C.E.: 재분류 안 함 | 범위 안 소계열 4,788, 중계열 2,391 / 한국외대 소계열 85, 중계열 35 | 학교별 신고에 의존(가설 문서 3 절) | '분류 불가' 범주로 둠. 소계열은 B 대상군 정의에만 사용 |
| 11 | 패널 연결 (두 해 모두 범위 안) | t=2024~2026 범위 안 37,405 행 → 32,006 쌍 (미연결 5,399) | 신설, 코드 변경 학과는 전년도 행이 없음 | 생존 편향을 한계로 명시 |
| 12 | 한국외대 학과코드 미연결 | 61 (2024 6 / 2025 17 / 2026 38) | 학부, 전공 개편 | B 예측 절 평가에서 제외하고 건수 공개. B 판정은 군 단위 풀링이라 연결 불필요 |
| 13 | 두 해 비율 유효 + 직전연도 재적 ≥ 30 | 32,006 → 27,316 → 25,867 → 23,114 쌍 | 사전 고정 설계 | 민감도: 재적≥10 25,008 / 재적≥50 21,193 / 전체 표본 25,836 |

## 표 5. 이슈별 건수 단계별 추적표

출처: 노트북 s3-20 / `data/processed/cleaning_track.csv`

| 이슈 | ① 원본 전체 | ② 중복 확인 후 | ③ 범위 안 (일반 대학 주간) | ④ 연결 쌍 (당해 기준) | ⑤ 분석 표본 (재적≥30) | 민감도 (재적≥10) | 민감도 (재적≥50) |
|---|---|---|---|---|---|---|---|
| (참고) 행 수 | 56,340 | 56,340 | 50,081 | 32,006 | 23,114 | 25,008 | 21,193 |
| 재적 = 0 | 2,500 | 2,500 | 2,261 | 276 | 0 | 0 | 0 |
| 재적 = 0 이면서 계 > 0 | 1,497 | 1,497 | 1,359 | 221 | 0 | 0 | 0 |
| 재적 = 0 인데 비율 기록됨(0%) | 1,697 | 1,697 | 1,516 | 95 | 0 | 0 | 0 |
| 계 > 재적 (재적 > 0) | 172 | 172 | 158 | 87 | 12 | 37 | 5 |
| 재계산 불일치 (> 0.01%p) | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 사유합 ≠ 계 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 비율 결측 | 6,372 | 6,372 | 5,585 | 4,595 | 0 | 0 | 0 |
| ㄴ 계 결측 | 5,569 | 5,569 | 4,840 | 4,414 | 0 | 0 | 0 |
| ㄴ 재적 0 (계 있음) | 803 | 803 | 745 | 181 | 0 | 0 | 0 |
| 폐교 | 493 | 493 | 0 | 0 | 0 | 0 | 0 |
| 신설 | 263 | 263 | 256 | 45 | 13 | 15 | 11 |
| 소계열 N.C.E. | 5,279 | 5,279 | 4,788 | 2,750 | 1,838 | 2,081 | 1,627 |
| 중계열 N.C.E | 2,677 | 2,677 | 2,391 | 1,261 | 839 | 967 | 733 |

④, ⑤의 이슈 건수는 '당해(t)' 행 기준이다. 분석 표본에 남은 '계 > 재적' 12 건은 당해 값이 100%를 넘는 경우로, 값을 고치지 않고 그대로 둔다(직전연도 재적≥30 조건은 전년도 기준).

신설 학교 학과 13 쌍은 v2 범위 조건(폐교만 제외)에 따라 표본에 남는다.

## 표 6. 비교: 판단에 따라 결과가 바뀌는 처리 (팀 결정 2026-11-11)

| 처리 | 선택지 A | 선택지 B | 결과 차이 | 팀 결정(날짜) | 되돌리는 스위치 |
|---|---|---|---|---|---|
| 공시 비율 vs 계÷재적 재계산 | 공시값 사용 | 계÷재적 재계산값 사용 | 사전 확인 결과 최대 차이 0.005%p(소수 둘째 자리 반올림 수준), 0.01%p 를 넘는 행은 0. 노트북 s3-04 에서 재측정 | **공시값 사용 (2026-11-11)** | `RATE_SOURCE` |

| 처리 | 선택지 A | 선택지 B | 결과 차이 | 팀 결정(날짜) | 되돌리는 스위치 |
|---|---|---|---|---|---|
| 최소 재적 기준 | 30 | 10 / 50 | 표본 23,114 vs 25,008 / 21,193 쌍. 결과 차이는 ④ 민감도 표 | 사전 고정: 30 | `MIN_ENROLL` |
| 분석 범위 | 일반 대학 주간 | 전체 표본 | 표본 23,114 vs 25,836 쌍. 결과 차이는 ④ 민감도 표 | 사전 고정: 일반 대학 주간 (2026-11-11) | `SCOPE` |
| B 대상군 | 어문 2 개 소계열 | + 국제지역학 소계열 | 결과 차이는 ④ 민감도 표 | 사전 고정: 어문 2 개 | `B_SUBFIELDS` |

## 표 7. 정제 전/후 집계

```
정제 전 전체 행 수:                 56,340   (s2-02)
범위 안 행 수 (일반 대학 주간):    50,081   (s3-16)
전년→당해 연결 쌍 (범위 안):       32,006   (s3-18)
분석 표본 (학습 t=2024, 2025):      15,608   (s3-19)
분석 표본 (테스트 t=2026):          7,506   (s3-19)
```

> 필터 결과 행 수가 0 이면 코드보다 조건을 먼저 의심한다(노트북에 assert 를 둔다).

## 표 8. 손대지 않기로 한 것 (이유 포함)

☐ **비율 100% 초과 행**: 값을 고치지 않고 표시만 한다. 최소 재적 기준으로 통제하고, 민감도로 영향을 확인한다.

☐ **사유 컬럼**: 사유합 = 계 정합성이 확인되면 보정하지 않는다.

☐ **y(중도탈락학생비율)**: 평균 대체 등 어떤 보정도 하지 않는다.

☐ **표준분류 대, 중, 소계열**

- ○ 학과를 재분류하지 않고, 수작업 매핑표도 만들지 않는다.
- ○ 애매한 학과는 데이터 값을 그대로 쓴다(예: 글로벌스포츠산업학부 = 경영, 경제 / 경영학).
- ○ N.C.E.는 하나의 '분류 불가' 범주로 둔다.
- ○ 이유: 팀이 분류를 바꾸면 결과를 보고 그룹을 고르는 위험이 생긴다. 분류가 갈리는 문제는 한계로 공개한다.

☐ **범위 밖 행**: 지우지 않고 `in_scope=False` 로 남긴다. 민감도 ②에서 다시 쓴다.

☐ **한국외대 학과코드 변동**: 학과명으로 억지로 이어 붙이지 않는다. 대신 B 는 군 단위 풀링으로 비교한다.

☐ **학부, 전공 이중 계상 가능성(한국외대)**: 값은 바꾸지 않는다. 재적 합계와 학교 공시 총재적을 대조해 확인 결과만 기록한다. `[확인 필요]`

☐ **재적 0 인데 비율 0%로 기록된 1,697 행**: 0%를 결측으로 바꾸지 않는다. 대신 `rate_valid`(재적>0)로 y 에서 빼고, 원본 값은 그대로 둔다.

☐ **신설 학교의 학과**: v2 범위 조건은 폐교만 제외한다. 전년도 행이 있는 신설 학교 학과(분석 표본 13 쌍)는 그대로 남긴다.

☐ **개편 전 잔류, 신설 초기로 추정되는 작은 단위**(한국외대 19 개, 연평균 재적 30 명 미만): 행과 값은 그대로 두고, 부록 R1 의 비율 순위에서만 '비율 해석 불가'로 표시해 뺀다(노트북 sE-02, 원판정 sE-01 은 그대로). 근거: 재적 감소, 학과코드 소멸, 탈락 사유 대부분 미복학. 개편 이력은 `[확인 필요]`.

☐ **기준연도 ≠ 공시연도 − 1 인 행**(연도별 101~172 행): 공시연도를 시간 축으로 쓴다. 기준연도는 바꾸지 않는다(s2-03).

# AI 활용 로그

## AI 활용 원칙

□ **허용**: 정제, 집계 코드 생성, 에러 해석, 개념 설명, 문장 다듬기

□ **기록 필수**: 무엇을 물었는가, 무엇을 받았는가, 어떻게 검증했는가, 채택/수정/기각

□ **금지**: 검증 없는 채택, 실행하지 않은 수치 기재, AI 가 만들거나 조작한 데이터 사용

□ **검증 방법**: 모든 수치는 노트북 셀 출력과 대조(셀 ID 표기), 가설, 판정 규칙은 결과 전에 git 태그로 고정

## 단계별 기록 (내가 지시한 것 / AI 가 제안한 것 / 채택, 수정, 기각한 것)

| 날짜 | 단계 | 내가 지시한 것 | AI 가 제안한 것 | 채택, 수정, 기각과 검증 |
|---|---|---|---|---|
| 11/08 | ① 문제 정의 | 공개 데이터로 답할 의사결정 질문을 누가, 무엇을, 질문 형식으로 강화 | 의사결정자, 분류 설계, 가설 초안, 판정 규칙 | 수정: 수치 기준을 팀 기준으로 명시하고 민감도로 보완 |
| 11/08 | ② 수집 | 행, 열, 중복, 결측, 정합성, 연결 가능성을 pandas 로 세기 | 사전 점검 수치(56,340×32, 결측 6,372 등) | 채택: 노트북 재실행으로 같은 값 확인(s2-02~s3-06) |
| 11/08 | ① 문제 정의 | 안내문 분량 요구 확인 | AI 가 "제안서 1 쪽 요구"라고 진술 | **수정**: 원문 확인 결과 분량 제한 없음 → AI 진술 정정 |
| 11/11 | ② 수집 | 일반 대학만 쓸지, 학교 유형이 섞인 구조 보여 주기 | 학교종류, 주야간, 학과특성 분포, 일반 대학 주간 범위 | 채택: 범위 50,081 행(88.9%), 전체 표본은 민감도로 |
| 11/11 | ③ 정제 | 표준분류가 학과명 단위로 일관된지 재기 | 중계열 27%, 소계열 46% 갈림, N.C.E. 9.4% | 채택: 수작업 매핑 없이 데이터 컬럼만 사용 |
| 11/11 | ① 문제 정의 | B 대상군 정의(국제지역학 포함 여부) | 처음엔 국제지역학 포함 제안 | **수정**: AI 가 측정 해석을 잘못 말했다가 재측정 → 국제지역학은 민감도로 |
| 11/11 | ① 문제 정의 | 의사결정자에 맞춘 가설 v2 설계 | 가설 A, B, 예측 절, R1, R2 후보 | **수정**: AI 가 전국 비교 방향을 근거 없이 가정 → 사용자 지적으로 판정에서 제외. 태그로 결과 전 고정 |
| 11/11 | ① 문제 정의 | k 와 오차 비용을 청중이 이해할 만큼 단순하게 | k = 작년 고위험 학과 수, 정밀도, 재현율 2 개 | 채택: 태그 hypotheses-locked-v3 |
| 11/11 | ③ 정제 | 공시 비율 vs 계÷재적 차이가 큰지 | 최대 0.005%p(반올림 수준) | 채택: 공시값 사용. AI 가 인용한 "68 행"은 재현 안 됨 → [확인 필요]로 기록 |
| 11/11 | ③ 정제 | 노트북 ③을 실제 코드로, 기대값 assert | 정제 코드, 로그, 추적표 | 채택: assert 전부 통과. 새 함정(재적 0 인데 비율 0% 1,697 행) 발견 |

| 날짜 | 단계 | 내가 지시한 것 | AI 가 제안한 것 | 채택, 수정, 기각과 검증 |
|---|---|---|---|---|
| 11/11 | ④ 분석 | 가설 A, B, 예측 절, 민감도, R1 구현 | A 맞음, B 기각, +1.7%p, 교집합 0 | 채택: 누수 assert, 시드 4 개 재현, 의학계열 완전 분리 진단. 사전 문서에 없던 세부 7 개는 공개 후 팀 검토 |
| 11/11 | ⑤ 발표 | 가능한 차트를 다 그리고 베스트 3 종 선택 | 후보 14 개, 5 개 기준 점수표 | 채택: 그림을 직접 보고 눈금, 라벨 겹침 4 건 수정 |
| 11/12 | ⑤ 발표 | 졸업논문 수업 PPT 양식으로 발표 자료 제작 | 슬라이드 생성 코드, 슬라이드용 그림 | 채택: 팀원 검토 후 표지, 표기 수정 반영 |
| 11/12 | ④ 분석 | 재적 1 명, 탈락 1 명 같은 순위를 근거와 함께 해석 보정 | 개편 전 잔류, 신설 초기 추정, R1 보정판(교집합 0→1) | 채택: 원판정은 유지하고 보정판을 나란히 공개 |
| 11/12 | ④ 분석 | 1 학년 단위 탈락이 소속 이동 때문인지, 비율 비교가 공정한지 | 소속 이동 아님 근거 3 개, 1 학년 탈락률 범위 비교 | 채택: 문구를 "1 학년 초기 이탈이 모여 보인다"로 수정 |
| 11/12 | ④ 분석 | 가설 B 반대 결과를 설명하는 문장 | 대안 설명 3 개, ①을 가장 강한 설명으로 제시 | **수정**: 연도별 확인 결과 ①은 2026 공시부터라 부분 설명 → 확인/추정 구분 |

## AI 진술을 바로잡은 사례

☐ 안내문 분량: AI 가 "1 쪽 요구"라고 했으나 원문에는 분량 제한이 없었음(원문 직접 확인)

☐ 국제지역학 분류: AI 가 측정 해석을 잘못 말했다가 재측정으로 정정, 주 분석에서 제외

☐ 전국 비교 방향: AI 가 근거 없이 방향을 가정 → 판정에서 빼고 결과 문구만 미리 고정

☐ 계획서 기준값 2 개(재계산 불일치 68 행, 국제지역학 28/22)는 노트북에서 재현되지 않아 [확인 필요]로 공개

☐ 반대 결과 설명: AI 가 "이탈이 앞 단계로 옮겨 갔다"를 가장 강한 설명이라 했으나, 그 단위는 2026 공시부터라 부분 설명임을 연도별 재계산으로 확인해 정정

전체 원본 기록: logs/AI 활용기록.md, 사용 프롬프트: docs/프롬프트_모음.md

# 기여도표

안내문 5 단계(① 문제 정의 / ② 수집 / ③ 정제 / ④ 분석 / ⑤ 발표)별로 **담당자**(초안 작성)와 **검토자**(교차 검토)를 적는다.

개인 점수는 이 표를 근거로 ±10% 조정된다(반영 비중 [확인 필요 — 교수 공지]). 담당은 팀이 정했다(2026-11-12). 단계별 담당, 검토 10 칸은 정승엽 4, 박유진 3, 신효주 3 이며 자기 검토는 없다. 공통 행은 안내문 요구 밖이라 전원으로 둔다.

Q&A 에서 교수는 발표하지 않은 팀원에게도 질문할 수 있다. 검토자도 해당 단계를 설명할 수 있어야 한다.

| 단계 | 세부 작업 | 담당자 | 검토자 | 산출물 |
|---|---|---|---|---|
| ① 문제 정의 | 의사결정 질문, 가설 A, B, 판정 규칙 고정 | 박유진 | 신효주 | `00_문제정의_가설.md`, 주제계획서 |
| ② 수집 | 원자료 다운로드, 출처, 이용 조건, 범위 정의, 측정 척도 | 박유진 | 정승엽 | `docs/수집_기록표.md`, `docs/data_description.md` |
| ③ 정제 | 품질 6 대 기준 진단, 범위 확정, 정제 로그 | 정승엽 | 박유진 | `logs/정제로그.md`, 노트북 §③ |
| ④ 분석 | EDA, 기술통계, 모델, 기준선, 민감도, 가설 A, B 판정 | 정승엽 | 신효주 | 노트북 §④ |
| ⑤ 발표 | 차트 3 종, 권고, 근거, 한계, 슬라이드, 보고서, 발표 | 신효주 | 정승엽 | 노트북 §⑤, `notebook/figures/`, `slides/`, `report/` |
| 공통 | AI 활용 로그 정리 | 전원 | 전원 | `logs/AI 활용기록.md` |
| 공통 | 재현성 확인 (다른 계정에서 처음부터 재실행) | 전원 | 전원 | `logs/재현성_확인표.md` |

## 기여 비율

| 팀원 | 비율(%) | 주요 기여 한 줄 |
|---|---|---|
| 정승엽 | 55 | 분석 설계와 실행 총괄: 결과 전 가설 고정(v1~v3), 범위 확정과 정제 로그, 예측 모델과 기준선 비교, 가설 A, B 판정, 해석 보정(개편 단위, 1 학년 단위), 발표 자료와 제출 문서, GitHub 와 팀 정본 노트북 관리 |
| 박유진 | 20 | 주제와 데이터 선정(대학알리미 학과별 중도탈락 공시), Colab 에서 최종 노트북 재현성 확인(핵심 수치 모두 일치), 개인 AI 활용 로그 작성 |
| 신효주 | 25 | 독립 분석 노트북 작성(정제 단계 기록, 기준선과 모델 비교, 민감도, 한국외대 학과군 부트스트랩)으로 팀 결과 교차 검증, 정제 로그 초안과 분석 작업 정리 |